

**PENERAPAN METODE PERAMALAN *HOLT-WINTERS* DAN LSTM (*LONG SHORT-TERM MEMORY*) DALAM PERANCANGAN KALENDER TANAM PADI SAWAH
(STUDI KASUS: KABUPATEN ACEH BESAR)**

TUGAS AKHIR

Diajukan untuk melengkapi tugas-tugas dan memenuhi syarat-syarat guna memperoleh gelar Sarjana Statistika

Oleh:

EMA DWI CHAIRANI
2108108010065



**PROGRAM STUDI STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA, BANDA ACEH
MARET, 2025**

PENGESAHAN

PENERAPAN METODE PERAMALAN *HOLT-WINTERS* DAN LSTM (*LONG SHORT-TERM MEMORY*) DALAM PERANCANGAN KALENDER TANAM PADI SAWAH (STUDI KASUS : KABUPATEN ACEH BESAR)

APPLICATION OF HOLT-WINTERS AND LSTM (LONG SHORT-TERM MEMORY) FORECASTING METHODS IN DESIGNING A RICE PLANTING CALENDAR (CASE STUDY: ACEH BESAR REGENCY)

Oleh:

Nama : Ema Dwi Chairani
NPM : 2108108010065
Program Studi : Statistika

Menyetujui:

Pembimbing I,

Pembimbing II,

Dr. Miftahuddin, S.Si., M.Si.
NIP. 197405252000031004

Ardiansyah, BSEE.,M.Sc.
NIP.197212261992011001

Mengetahui:

Dekan FMIPA
Universitas Syiah Kuala,

Koordinator Program Studi Statistika
FMIPA Universitas Syiah Kuala,

Prof. Dr. Taufik Fuadi Abidin, S.Si., M.Tech.
NIP. 197010081994031002

Prof. Dr. Zurnila Marli Kesuma, S.Si., M.Si.
NIP. 196903061994122001

Lulus Sidang Sarjana pada hari Rabu 5 Maret 2025

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini,

Nama Lengkap : Ema Dwi Chairani
Tempat/tanggal lahir : Batam/ 2 Februari 2001
NPM : 2108108010065
Departemen : Statistika
Fakultas : Matematika dan Ilmu Pengetahuan Alam
Judul : Penerapan Metode Peramalan *Holt-Winters* dan LSTM (*Long Short-Term Memory*) dalam Perancangan Kalender Tanam Padi Sawah (Studi Kasus : Kabupaten Aceh Besar)

Menyatakan dengan ini sesungguhnya bahwa Laporan Tugas Akhir saya dengan judul seperti di atas adalah **hasil karya saya sendiri** bersama dosen pembimbing dan **bebas plagiasi**.

Jika ternyata di kemudian hari terbukti bahwa Laporan Tugas Akhir merupakan hasil plagiasi, saya bersedia menerima sanksi yang berlaku di Universitas Syiah Kuala.

Banda Aceh, 10 Maret 2024
Yang menyatakan,

Ema Dwi Chairani
NPM. 2108108010065

ABSTRAK

Peramalan merupakan metode untuk memprediksi kejadian di masa depan menggunakan data historis. Pemilihan metode peramalan yang tepat sangat penting bagi keberhasilan sektor pertanian, terutama di daerah yang ketergantungannya tinggi terhadap kondisi iklim yaitu sawah tadah hujan di wilayah Aceh Besar. Dengan menggunakan metode Holt-Winters dan LSTM (Long Short-Term Memory) untuk memprediksi variabel curah hujan, suhu udara dan kelembapan udara (relatif) di wilayah Aceh Besar menggunakan data harian dari dua sumber data iklim yaitu Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) dan National Aeronautics and Space Administration (NASA) untuk mengevaluasi perbedaan akurasi prediksi antara kedua metode peramalan tersebut. Perencanaan berbasis data diperlukan untuk memenuhi kebutuhan sumber pangan di Aceh Besar. Melalui penerapan metode peramalan tersebut, penelitian ini bertujuan untuk meminimalkan risiko gagal panen akibat perubahan iklim. Untuk mencapai tujuan ini, data dianalisis melalui tahapan, termasuk pelatihan dan pengujian model. Metode Holt-Winters digunakan karena kemampuannya dalam menangkap pola musiman, sedangkan metode LSTM digunakan karena kemampuan dalam memproses data dengan pola kompleks dan jangka panjang. Akurasi model diukur dengan Root Mean Square Error (RMSE) dan Mean Absolute Error (MAE). Hasil analisis menunjukkan metode LSTM memiliki performa prediksi yang lebih baik dibandingkan Holt-Winters untuk semua variabel penelitian dengan proporsi data pelatihan 90% dengan dataset NASA memberikan tingkat akurasi lebih baik dengan RMSE 0,057 dan MAE 0,033 pada variabel curah hujan, RMSE 0,107 dan MAE 0,083 pada variabel kelembapan udara (relatif), dan RMSE 0,080 dan MAE 0,064 pada variabel suhu udara. Berdasarkan hasil peramalan, disusun kalender tanam padi sawah yang mencakup jadwal tanam dan masa istirahat tanam (bera). Masa tanam dimulai pada bulan September hingga Mei dan masa bera ditemukan berada pada bulan Juni hingga Agustus. Kalender tanam ini diharapkan dapat membantu petani dalam mengelola kegiatan pertanian secara lebih efisien dan adaptif terhadap perubahan iklim, sehingga produktivitas padi di wilayah Aceh Besar dapat ditingkatkan.

Kata Kunci : Holt-Winters, LSTM, Data Iklim, Kalender Tanam Padi Sawah, Aceh Besar

ABSTRACT

Forecasting is a method used to predict future events based on historical data. The selection of the appropriate forecasting method is critical for the success of agriculture, especially in regions heavily reliant on climatic conditions such as rain-fed rice fields in Aceh Besar. Using the Holt-Winters and LSTM (Long Short-Term Memory) methods, this study aims to predict variables such as rainfall, air temperature, and relative humidity in Aceh Besar using daily data from two climate data sources: the Meteorology, Climatology, and Geophysics Agency (BMKG) and the National Aeronautics and Space Administration (NASA). The study aims to evaluate the accuracy differences between these two forecasting methods. Data-driven planning is essential to meet the food source requirements in Aceh Besar. By applying these forecasting methods, this research seeks to minimize the risk of crop failure due to climate change. To achieve this goal, data are analyzed through multiple stages, including model training and testing. The Holt-Winters method is employed to capture seasonal patterns, while the LSTM method is used for processing data with complex and long-term patterns. Model accuracy is assessed using Root Mean Square Error (RMSE) and Mean Absolute Error (MAE). The results indicate that the LSTM method exhibits superior prediction accuracy across all study variables, with a training data proportion of 90%. The dataset from NASA offers better accuracy with RMSE of 0.057 and MAE of 0.033 for rainfall, RMSE of 0.107 and MAE of 0.083 for relative humidity, and RMSE of 0.080 and MAE of 0.064 for air temperature. Based on the forecasting results, a rice planting calendar is developed, detailing planting schedules and fallow periods (bera). The planting season begins in September and extends until May, with the fallow period occurring from June to August. This planting calendar is expected to assist farmers in managing agricultural activities more efficiently and adaptively in response to climate change, thereby enhancing rice productivity in Aceh Besar

Keywords: Holt-Winters, LSTM, Climate Data, Rice Planting Calendar, Aceh Besar

KATA PENGANTAR

Puji syukur Alhamdulillah penulis ucapkan atas kehadiran Allah SWT yang telah melimpahkan rahmat-Nya sehingga penulis dapat menyelesaikan penulisan Tugas Akhir yang berjudul **“Penerapan Metode Peramalan *Holt-Winters* dan LSTM (*Long Short Term Memory*) dalam Perancangan Kalender Tanam Padi Sawah Berdasarkan (Studi Kasus : Kabupaten Aceh Besar)”**. Selawat dan salam penulis sanjungkan kepada Nabi Besar Muhammad SAW.

Tugas Akhir ini merupakan salah satu syarat yang harus dipenuhi untuk memperoleh gelar Sarjana di Departemen Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Syiah Kuala. Penyelesaian penulisan Tugas Akhir ini tidak terlepas dari bimbingan, bantuan, dan dukungan dari berbagai pihak. Ucapan terima kasih diucapkan kepada:

1. Kedua orang tua saya yang tercinta, tiada kata yang cukup untuk menggambarkan rasa terima kasih yang mendalam atas segala doa, kasih sayang, dan pengorbanan yang tiada pernah berhenti. Setiap langkah dalam perjalanan ini adalah bukti dari cinta dan dukungan kalian yang tak tergantikan. Umi Flora Panjaitan, terima kasih atas doa-doa yang tak pernah terputus, bahkan saat saya tak menyadarinya. Ayah MHD Ali Nafiah, terima kasih sudah menjadi ayah yang selalu menjadi garda terdepan memberikan solusi terbaik dan terimakasih atas setiap peluh yang engkau teteskan demi memastikan saya bisa berdiri di titik ini. Kalian adalah alasan saya berjuang.
2. Ibu Prof. Dr. Zurnila Marli Kesuma, S.Si., M.Si. selaku Ketua Departemen Statistika dan Bapak Marzuki, S.Si, M.Si. selaku Sekretaris Departemen Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Syiah Kuala.
3. Bapak Dr. Miftahuddin, S.Si., M.Si. selaku dosen wali sekaligus dosen Pembimbing I dan Bapak Ardiansyah, BSEE., M.Sc. selaku dosen Pembimbing II yang telah meluangkan waktunya serta memberikan saran, ide, pemahaman, dukungan, arahan, dan bimbingan kepada penulis sehingga proposal penelitian ini dapat terselesaikan.

4. Ibu Nurhasanah, S.Si., M.Si. Bapak Dr. Munawar, S.Si., M.App.Stats., dan Ibu Latifah Rahayu Siregar, S.Si., M.Sc., selaku dosen penguji yang telah memberikan saran dan masukan agar Tugas Akhir dapat terselesaikan dengan baik.
5. Bapak/Ibu dosen Departemen Statistika yang telah memberikan ilmu dan wawasan kepada penulis, serta Staf Departemen Statistika yang telah membantu penulis dalam administrasi selama masa studi di Departemen Statistika.
6. Saudari-saudari tersayang yang telah kompak bersama dan menjaga dalam masa masa sulit kita. Kakak Rodhiah Apriani A.Md.Kep, Adik Intan Aini dan Adik Andini Putri Pratiwi.
7. Teman-teman seperjuangan Departemen Statistika Angkatan 2021 yang telah memberikan bantuan, semangat, dukungan, dan motivasi kepada penulis..
8. Terakhir terimakasih untuk diri sendiri, yang telah bertahan melalui segala keraguan, kelelahan, dan tantangan selama proses ini. Meski tidak selalu mudah, kamu telah membuktikan bahwa setiap langkah sekecil apa pun memiliki arti. Untuk semua usaha dan keteguhan hati, kamu berhak merasa bangga. Semoga perjalanan ini menjadi pengingat bahwa kamu mampu, dan bahwa perjuangan hari ini adalah bekal untuk mimpi-mimpi yang lebih besar di masa depan.

Terlepas dari semua itu, penulis menyadari sepenuhnya bahwa penyusunan Tugas Akhir ini masih memiliki banyak kekurangan. Oleh karena itu, penulis mengharapkan kritik dan saran yang dapat membangun demi perbaikan di masa yang akan datang. Akhir kata, penulis berharap semoga Tugas Akhir ini dapat memberikan manfaat bagi perkembangan ilmu pengetahuan khususnya di bidang Statistika.

Banda Aceh, 10 Maret 2024

Ema Dwi Chairani
NPM. 2108108010065

DAFTAR ISI

	<i>Halaman</i>
Halaman Judul	i
Halaman Pengesahan	ii
Pernyataan Bebas Plagiasi	iii
Abstrak	iv
Abstract	v
Kata Pengantar	vi
Daftar Isi	viii
Daftar Tabel	x
Daftar Gambar	xi
Daftar Lampiran	xii
 BAB I PENDAHULUAN	
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian.....	4
1.4 Manfaat Penelitian.....	5
 BAB II TINJAUAN KEPUSTAKAAN	
2.1 Peramalan	6
2.2 <i>Holt-Winters</i>	6
2.3 <i>Long Short-Term Memory (LSTM)</i>	8
2.4 Akurasi Model	10
2.4.1 <i>Root Mean Square Error (RMSE)</i>	10
2.4.2 <i>Mean Absolute Error (MAE)</i>	10
2.5 Faktor Iklim	12
2.5.1 Curah Hujan	12
2.5.2 Kelembapan Udara Relatif	12
2.5.3 Suhu Udara	13
2.6 Pola Tanam Padi Sawah dan Kalender Tanam Padi	13
2.7 <i>The Power Project NASA</i>	14
 BAB III METODE PENELITIAN	
3.1 Data dan Variabel Penelitian	16
3.2 Prosedur Analisis Data	17
3.3 Diagram Alir Penelitian.....	18
 BAB IV HASIL DAN PEMBAHASAN	
4.1 Persiapan Data	19
4.2 Analisis Deskriptif.....	19
4.2.1 Ringkasan Statistik.....	19
4.2.2 Plot Deret Waktu.....	22
4.2.3 Dekomposisi Deret Waktu	26
4.2.4 Boxplot	30

4.3	Pembagian Data Pelatihan dan Pengujian	32
4.4	<i>Holt-Winters</i>	33
4.4.1	Perancangan Model <i>Holt-Winters</i>	33
4.4.2	Peramalan dengan <i>Holt-Winters</i>	34
4.5	<i>Long Short-Term Memory</i> (LSTM).....	35
4.5.1	Perancangan Model LSTM	35
4.5.2	Peramalan dengan LSTM.....	36
4.6	Pemilihan Model Terbaik	36
4.7	Peramalan Periode Selanjutnya	37
4.8	Penyusunan Kalender Tanam	40
 BAB V KESIMPULAN DAN SARAN		
5.1	Kesimpulan.....	41
5.2	Saran	41
 DAFTAR KEPUSTAKAAN		42
 LAMPIRAN		45

DAFTAR TABEL

	<i>Halaman</i>
Tabel 2.1 Tabel kategori intensitas curah hujan	12
Tabel 2.2 Tabel kesetaraan Iklim	14
Tabel 3.1 Variabel penelitian	16
Tabel 4.1 Ringkasan statistik setiap variabel penelitian sebelum imputasi	19
Tabel 4.2 Ringkasan statistik setiap variabel penelitian setelah imputasi	20
Tabel 4.3 Jumlah data berdasarkan kategori curah hujan	22
Tabel 4.4 Model Holt-Winters pada setiap skenario pembagian data	33
Tabel 4.5 Tingkat akurasi data pelatihan Model <i>Holt-Winters</i>	35
Tabel 4.6 Tingkat akurasi data pelatihan Model LSTM	36
Tabel 4.7 Model tingkat akurasi terbaik	37
Tabel 4.8 Kategori curah hujan hasil peramalan	38
Tabel 4.9 Tabel kesetaraan iklim	39
Tabel 4.10 Tabel kalender tanam Aceh Besar tahun 2025	40

DAFTAR GAMBAR

	<i>Halaman</i>
Gambar 2.1 Arsitektur LSTM	9
Gambar 4.1 Plot deret waktu curah hujan sebelum imputasi	22
Gambar 4.2 Plot deret waktu curah hujan sesudah imputasi	23
Gambar 4.3 Plot deret waktu kelembapan udara relatif sebelum imputasi	24
Gambar 4.4 Plot deret waktu kelembapan udara relatif setelah imputasi	24
Gambar 4.5 Plot deret waktu suhu udara sebelum imputasi	25
Gambar 4.6 Plot deret waktu suhu udara setelah imputasi	26
Gambar 4.7 Dekomposisi deret waktu curah hujan	27
Gambar 4.8 Dekomposisi deret waktu kelembapan udara relatif	28
Gambar 4.9 Dekomposisi deret waktu suhu udara	29
Gambar 4.10 Boxplot curah hujan	30
Gambar 4.11 Boxplot kelembapan udara relatif	31
Gambar 4.12 Boxplot suhu udara	32
Gambar 4.13 Hasil peramalan curah hujan 365 hari selanjutnya	37
Gambar 4.14 Hasil peramalan kelembapan udara relatif 365 hari selanjutnya	38
Gambar 4.15 Hasil peramalan suhu udara 365 hari selanjutnya	39

DAFTAR LAMPIRAN

	<i>Halaman</i>
Lampiran 1 Data penelitian	45
Lampiran 2 Ringkasan Statistik dan Proses Imputasi	46
Lampiran 3 Pemrosesan Plot Deret Waktu	46
Lampiran 4 Pemrosesan Plot Dekomposisi	47
Lampiran 5 Pemrosesan Boxplot	47
Lampiran 6 Model Holt-Winters dan Perbandingan Hasil Peramalan Curah Hujan BMKG	47
Lampiran 7 Model Holt-Winters dan Perbandingan Hasil Peramalan Kelembapan Udara BMKG	49
Lampiran 8 Model Holt-Winters dan Perbandingan Hasil Peramalan Suhu Udara BMKG	50
Lampiran 9 Model Holt-Winters dan Perbandingan Hasil Peramalan Curah Hujan NASA	52
Lampiran 10 Model Holt-Winters dan Perbandingan Hasil Peramalan Kelembapan Udara NASA	53
Lampiran 11 Model Holt-Winters dan Perbandingan Hasil Peramalan Suhu Udara NASA	55
Lampiran 12 Model LSTM	56
Lampiran 13 Peramalan curah hujan BMKG dengan Metode LSTM	56
Lampiran 14 Peramalan kelembapan udara relatif BMKG dengan Metode LSTM	57
Lampiran 15 Peramalan suhu udara BMKG dengan Metode LSTM	58
Lampiran 16 Peramalan curah hujan NASA dengan Metode LSTM	59
Lampiran 17 Peramalan kelembapan udara relatif NASA dengan Metode LSTM	60
Lampiran 18 Peramalan suhu udara NASA dengan Metode LSTM	61
Lampiran 19 Hasil peramalan dengan metode terbaik dengan keputusan kesetaraan iklim LSTM	62
Lampiran 20 Hasil Kalender Tanam	63
Lampiran 21 Biodata	64

BAB I

PENDAHULUAN

1.1 LATAR BELAKANG

Peramalan adalah proses untuk meramalkan atau memprediksi suatu situasi di masa depan dengan menggunakan metode tertentu. Peramalan dilakukan dengan menggunakan informasi terbaik untuk mencapai target yang diinginkan. Meramalkan peristiwa yang mungkin terjadi di masa depan diperlukan agar siap untuk menghadapinya (Pertiwi, 2020). Perkembangan metode peramalan telah memungkinkan penggunaan yang lebih canggih dan akurat untuk menangani pola data deret waktu yang kompleks.

Metode *Holt-Winters* merupakan salah satu teknik peramalan yang menggabungkan tiga komponen utama: level, tren, dan *seasonality*. Metode ini sesuai untuk data deret waktu yang menunjukkan pola musiman dengan atau tanpa tren. Komponen level menunjukkan nilai dasar dari data, tren menunjukkan arah perubahan data dari waktu ke waktu, dan *seasonality* menyajikan pola berulang dalam data berdasarkan musim (Febriyanti & Rifai, 2022). Dengan mempertimbangkan ketiga komponen ini, metode *Holt-Winters* dapat memodelkan data deret waktu yang memiliki variasi musiman dengan baik. Hal ini membuatnya sesuai untuk peramalan data iklim yang sering kali menunjukkan pola musiman. Kelebihan lain dari metode ini adalah kemampuannya untuk mengatasi perubahan dalam pola musiman dan tren, sehingga memberikan hasil peramalan yang lebih akurat.

Metode *Holt-Winters* merupakan metode efektif yang diaplikasikan dalam meramalkan data deret waktu, namun di era *Artificial Intelligence* berbagai metode *Machine Learning* juga berkembang dengan pesat dalam meramalkan data deret waktu. *Machine Learning* merupakan algoritma yang bekerja selayaknya kecerdasan manusia bekerja, semakin banyak informasi dan kejadian yang dipelajari maka semakin pandai dan akurat kemampuan berpikir dalam menyelesaikan suatu permasalahan. *Long Short Term Memory* (LSTM) merupakan contoh model *Machine Learning* yang juga populer dalam meramalkan data deret waktu. (Setiawan et al., 2023).

Metode *Long Short-Term Memory* (LSTM) adalah bagian dari *Recurrent Neural Network* (RNN) memiliki kemampuan untuk menangani dependensi jangka panjang dalam data deret waktu. Keunggulan LSTM dalam mengenali dan meramalkan pola dari data historis membuatnya sangat efektif untuk peramalan data iklim yang kompleks dan tidak linear. LSTM mampu belajar dari data iklim historis untuk mengidentifikasi keterkaitan jangka panjang antara variabel-variabel iklim, seperti suhu, curah hujan, dan kelembapan. Hal ini membuat LSTM menjadi metode yang efektif untuk memodelkan dan meramalkan kondisi iklim (Lattifia et al., 2022).

Produktivitas padi sangat dipengaruhi oleh kondisi iklim. Dampak dari perubahan iklim terhadap produksi pertanian secara khusus meliputi dua hal, yaitu: hilangnya acuan masa tanam dalam pertanian dan penurunan hasil produksi pertanian akibat terjadinya kegagalan panen. Bila hal ini terjadi terus menerus, dapat menyebabkan kerugian pada sektor pertanian lokal dan secara permanen akan mengancam ketahanan pangan nasional (Pryanto et al., 2013). Ketidakstabilan sektor pertanian terhadap perubahan iklim ini juga memengaruhi stabilitas ekonomi masyarakat di Aceh Besar yang bergantung pada sektor pertanian.

Dengan wilayah yang mencakup persawahan yang luas, serta posisi Kota Banda Aceh yang berdampingan secara geografis menjadikan Aceh Besar sebagai pendukung pangan masyarakat Kota Banda Aceh. Padi sawah di Aceh Besar merupakan salah satu komoditas utama yang memberikan kontribusi besar terhadap perekonomian daerah, serta berfungsi sebagai sumber pangan pokok bagi masyarakat.

Curah hujan, suhu, dan kelembapan udara merupakan faktor lingkungan utama yang secara langsung memengaruhi pertumbuhan dan perkembangan tanaman padi. Air dari curah hujan adalah kebutuhan utama untuk irigasi dan keberlangsungan tanaman, karena air sebagai pelarut untuk mengangkut unsur hara yang diperlukan oleh tanaman dari tanah dan juga untuk mendukung proses fotosintesis. Suhu udara tinggi dapat mempercepat pertumbuhan padi dan proses respirasi, namun apabila terlalu tinggi akan meningkatkan kerusakan tanaman padi (Novelia et al., 2024). Kelembapan udara terlalu rendah menyebabkan proses fotosintesis tidak dapat menghasilkan energi yang cukup untuk tumbuhan hidup sehingga mengalami kekeringan dan mati. Sedangkan pada kelembapan yang terlalu tinggi, jamur dan

bakteri dapat tumbuh berkembang menyebabkan kerusakan atau pembusukan tumbuhan.

Variabilitas iklim mengakibatkan ketidakstabilan produksi padi, ketika perubahan sistem iklim bumi menghasilkan pola cuaca baru seperti pergeseran musim walaupun sifatnya sementara (DLHK Aceh, 2023). Perubahan pola cuaca dapat menyebabkan ketidakpastian dalam waktu tanam dan panen. Hal ini sering kali mengakibatkan peningkatan risiko gagal panen. Oleh karena itu, diperlukan suatu pendekatan yang mampu memprediksi kondisi iklim dengan akurasi tinggi untuk membantu petani dalam merencanakan aktivitas pertanian mereka dengan merancang kalender tanam padi sawah yang optimal, yang dapat membantu petani menentukan waktu tanam yang tepat untuk memaksimalkan hasil panen.

Metode peramalan digunakan untuk memprediksi kejadian di masa depan berdasarkan data historis yang ada. Dalam bidang pertanian, peramalan iklim dapat memberikan informasi yang berharga bagi petani untuk merencanakan waktu tanam, mengatur penggunaan air terutama sawah tadah hujan, dan mengelola sumber daya pertanian lainnya secara efisien.

Berdasarkan penelitian yang dilakukan Rismawati dan Darsyah (2018), penelitian ini membandingkan metode peramalan *Moving Average* dan *Exponential Smoothing Holt Winters* untuk menentukan peramalan inflasi di Indonesia. Hasil dari penelitian ini menunjukkan hasil metode *Holt-Winters* yang terbaik dapat dilihat dari nilai residu yang paling kecil dengan MAPE 8,34 sedangkan nilai MAPE dengan *Moving Average* ialah 8,92. Penelitian lainnya yang dilakukan oleh Rosita dan Moonlight (2024) dengan membandingkan beberapa metode prediksi untuk Nilai Jual USD: *Holt-Winters*, *Holt's*, dan *Single Exponential Smoothing*. Secara keseluruhan mengungkapkan keunggulan *Holt-Winters* dalam akurasi dan efisiensi waktu yang memadai dan mengindikasikan dengan kinerja yang lebih baik. Selanjutnya Carnegie dan Chairani (2023) melakukan penelitian dengan menyatakan bahwa model LSTM memiliki performa terbaik dalam memprediksi curah hujan. Pada penelitian yang dilakukan Selle et al. (2022) melakukan prediksi penggunaan listrik dengan membandingkan metode LSTM dan *Recurrent Neural Network* (RNN), menyimpulkan bahwa LSTM memiliki kinerja yang lebih baik dan mampu

menurunkan nilai galat pada penggunaan deret waktu yang lebih panjang dalam melakukan peramalan.

Dengan menerapkan metode *forecasting Holt-Winters* dan LSTM untuk mendapatkan model terbaik sehingga dapat dilakukan peramalan yang akurat sebagai gambaran iklim dan cuaca masa depan dan menghasilkan kalender tanam yang dapat dijadikan acuan pola tanam padi sawah oleh para petani.

1.2 RUMUSAN MASALAH

Berdasarkan penjelasan yang telah diuraikan dalam latar belakang, diketahui bahwa Kabupaten Aceh Besar memiliki peran sebagai daerah penyedia kebutuhan pangan terdekat bagi Kota Banda Aceh. Perubahan pola curah hujan, kelembapan udara (relatif), dan suhu udara yang tidak menentu dapat memengaruhi waktu tanam dan hasil panen padi. Oleh karena itu, diperlukan peramalan curah hujan, kelembapan udara (relatif), dan suhu udara yang akurat sebagai dasar penyusunan kalender tanam padi agar petani dapat menentukan waktu tanam yang optimal.

Metode peramalan Holt-Winters memiliki kemampuan dalam menangkap pola musiman dan LSTM dapat memodelkan data yang lebih kompleks. Namun penerapan kedua metode ini pada peramalan curah hujan, kelembapan udara (relatif), dan suhu udara perlu diteliti lebih lanjut untuk membandingkan hasil peramalan yang akurat guna pengambilan keputusan dalam merancang kalender tanam padi sawah di Kabupaten Aceh Besar.

1.3 TUJUAN PENELITIAN

Adapun tujuan yang ingin dicapai dari penelitian ini adalah sebagai berikut:

1. Mendapatkan model dengan akurasi terbaik diantara model *Holt-Winters* dan LSTM dalam meramalkan curah hujan, kelembapan udara (relatif), dan suhu udara di Kabupaten Aceh Besar menggunakan data harian dari BMKG dan NASA.
2. Mengetahui masa tanam padi sawah di Kabupaten Aceh Besar yang dirancang dalam bentuk Kalender Tanam

1.4 MANFAAT PENELITIAN

Manfaat dari penelitian ini adalah sebagai berikut:

1. Memberikan informasi mengenai metode peramalan yang efektif dalam meramalkan kondisi iklim berdasarkan variabel curah hujan, kelembapan udara (relatif), dan suhu udara di Kabupaten Aceh Besar.
2. Hasil penelitian diharapkan dapat memberikan panduan praktis bagi petani dalam menentukan waktu tanam yang tepat untuk meningkatkan produktivitas dan ketahanan pangan di Kabupaten Aceh Besar.
3. Memberikan informasi, gambaran, dan bahan bacaan kepada peneliti lain terutama terkait dengan metode peramalan *Holt-Winters* dan LSTM pada data iklim

BAB II

TINJAUAN KEPUSTAKAAN

2.1 PERAMALAN

Menurut Hutapea dan Siahaan (2023) menyatakan bahwa peramalan yaitu perkiraan tentang sebuah kejadian yang mendatang didasarkan data pada masa lampau yang dianalisis secara ilmiah. Peramalan diperlukan dikarenakan adanya ketidaksamaan waktu (*time lag*) antara kesadaran yang membutuhkan sebuah peraturan baru dengan waktu pelaksanaan peraturan tersebut.

Dalam metode peramalan, terdapat dua pendekatan utama, yaitu pendekatan kualitatif dan kuantitatif. Pendekatan kualitatif melibatkan peramalan berdasarkan pendapat atau opini pihak terkait, terutama ketika tidak ada informasi dari data historis yang dapat dijadikan dasar peramalan. Contohnya saat memperkenalkan produk baru yang belum memiliki riwayat sebelumnya. Di sisi lain, metode peramalan dengan pendekatan kuantitatif menggunakan data historis sebagai landasan untuk membuat perkiraan (Montgomery et al., 2024).

2.2 HOLT-WINTERS

Metode *Holt-Winters* merupakan salah satu variasi dari *Exponential Smoothing*. Metode ini berawal dari *Holt* (1957) dan *Winter* (1960) yang memperluas metode *Holt* untuk menangkap pola musiman dalam data. Metode ini memungkinkan data dimodelkan dengan level, tren, dan faktor musiman yang semuanya diperbarui dengan perataan eksponensial. Dalam metode *Holt-Winters* digunakan persamaan peramalan (F_t) dan tiga persamaan pemulusan yang terdiri dari persamaan untuk level (L_t), tren (b_t), dan komponen *seasonal* (S_t) dengan parameter pemulusan berupa α , β , dan γ . Besarnya koefisien α , β , dan γ memiliki jarak di antara 0 dan 1 yang ditentukan secara subjektif atau dengan meminimalkan kesalahan dari estimasi tersebut (Hyndman et al., 2008).

Terdapat dua metode *Holt-Winters* berdasarkan tipe musimannya, yaitu multiplikatif dan aditif. Dalam kasus aditif digunakan jika pola musimannya konstan sementara kasus multiplikatif untuk digunakan jika pola musimannya sebanding dengan tingkatan pada tren (Praasetyo et al., 2023).

Persamaan dasar *Holt-winters* dengan metode multiplikatif dapat dilihat pada Persamaan (2.1), (2.2), (2.3), (2.4).

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha) (L_{t-1} + b_{t-1}) \quad (2.1)$$

$$b_t = \beta (L_t + L_{t-1}) + (1 - \beta) b_{t-1} \quad (2.2)$$

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma) S_{t-s} \quad (2.3)$$

$$F_{t+m} = (L_t + m b_t) S_{t+m-s} \quad (2.4)$$

Inisialisasi nilai awal pada model aditif dapat dilakukan dengan persamaan sebagai berikut.

$$L_o = \frac{1}{s} (Y_1 + Y_2 + \dots + Y_s) \quad (2.5)$$

$$b_o = \frac{1}{s} \left[\frac{Y_{s+1} - Y_1}{s} + \frac{Y_{s+2} - Y_2}{s} + \dots + \frac{Y_{s+s} - Y_s}{s} \right] \quad (2.6)$$

$$S_t = \frac{Y_t}{L_o} \quad (2.7)$$

Keterangan

L_t : level pada periode t

b_t : tren pada periode t

S_t : komponen *seasonal* periode t

F_{t+m} : peramalan pada periode $t + m$

α, β, γ : parameter *smoothing* yang harus bernilai pada interval 0 hingga 1,

m : jumlah ramalan ke depan

s : panjang musiman (misalnya jumlah bulan atau kuartal dalam setahun, dan Y_t mewakili data yang diamati pada titik waktu t)

Selain itu, persamaan dasar *Holt-Winters* dengan metode aditif memiliki perbedaan walaupun tidak signifikan dengan persamaan sebelumnya dapat dilihat pada persamaan (2.5), (2.6), (2.7), (2.8) (Bisht, 2021).

$$L_t = \alpha (Y_t - S_{t-s}) + (1 - \alpha) (L_{t-1} + b_{t-1}) \quad (2.8)$$

$$b_t = \beta (L_t + L_{t-1}) + (1 - \beta) b_{t-1} \quad (2.9)$$

$$S_t = \gamma(Y_t + L_t) + (1 - \gamma) S_{t-s} \quad (2.10)$$

$$F_{t+m} = (L_t + mb_t)S_{t+m-s} \quad (2.11)$$

Inisialisasi nilai awal pada model aditif dapat dilakukan dengan persamaan sebagai berikut.

$$L_o = \frac{1}{s}(Y_1 + Y_2 + \dots + Y_s) \quad (2.12)$$

$$b_0 = \frac{1}{s} \left[\frac{Y_{s+1}-Y_1}{s} + \frac{Y_{s+2}-Y_2}{s} + \dots + \frac{Y_{s+s}-Y_s}{s} \right] \quad (2.13)$$

$$S_t = Y_t - L_o \quad (2.14)$$

Keterangan

L_t : level pada periode t

b_t : tren pada periode t

S_t : komponen *seasonal* periode t

F_{t+m} : peramalan pada periode $t + m$

α, β, γ : parameter *smoothing* yang harus bernilai pada interval 0 hingga 1,


m : jumlah ramalan ke depan

s : panjang musiman (misalnya jumlah bulan atau kuartal dalam setahun,
dan Y_t mewakili data yang diamati pada titik waktu t)

2.3 LONG SHORT-TERM MEMORY

Hochreiter dan Schmidhuber memperkenalkan model *Long Short-Term Memory* (LSTM) pada tahun 1997. Model LSTM adalah tipe dari *Recurrent Neural Network* (RNN) yang merupakan bagian dari *deep learning*. LSTM sangat cocok untuk mengklasifikasi, memproses dan membuat prediksi berdasarkan data deret waktu (Agarwal et al., 2021). LSTM dikenalkan untuk menyelesaikan masalah *vanishing gradient* yang terjadi dalam arsitektur Vanilla RNN pada saat menyimpan memori dalam jangka panjang. Hal ini karena LSTM memiliki unit yang unik yang dapat mempelajari kapan waktu untuk membuka dan menutup gerbang dalam jaringan untuk mengatur pergerakan *error* yang konstan dalam jaringan tersebut (Sagheer & Kotb, 2019).

Arsitektur LSTM terdiri dari *cell* (bagian memori LSTM), *input gate*, *output gate* dan *forget gate*. Setiap dari komponen memiliki peran spesifik dalam fungsi LSTM. *Cell* untuk menyimpan atau membuang informasi tertentu. *Forget Gate* untuk memutuskan informasi akan disimpan atau dibuang oleh *cell state*. *Input Gate* untuk memutuskan banyaknya informasi yang akan disimpan dalam *cell*. *Output Gate* untuk menentukan *hidden state* selanjutnya. (Thomas, 2023)



Gambar 2.1 Arsitektur LSTM (Thomas, 2023).

Proses LSTM diawali dengan menerima *input vector* (x_t) dan *state* sebelumnya (h_{t-1}, c_{t-1}). Yang mana h_t merupakan *hidden state* dan c_t merupakan *cell state*. Selanjutnya *forget gate* (f_t) memutuskan informasi yang dibuang oleh *cell state* menggunakan *input vector* dan *hidden state* sebelumnya untuk menghasilkan angka antara 0 dan 1 pada setiap nilai di *cell state* c_{t-1} . Dengan angka 1 berarti “simpan sepenuhnya” dan angka 0 mengartikan “buang sepenuhnya”.

Berikut persamaan *Forget Gate* :

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.15)$$

Keterangan :

f_t : *forget gate*

σ : *sigmoid function*

W_f : bobot pada *forget gate*

h_{t-1} : hasil *output* pada *time step* $t - 1$

x_t : *input* pada *time step* t

b_f : bias pada *forget gate*

Pada proses *input gate* (i_t) terdapat dua bagian yaitu *sigmoid* (*input gate layer*) memutuskan nilai mana yang akan diperbarui dan lapisan $\tan(h)$ membuat vektor nilai baru ($c_t^{\sim}$) yang dapat ditambahkan ke *state*.

Berikut persamaan *Input Gate* :

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.16)$$

Keterangan :

i_t : *input gate*

σ : *sigmoid function*

W_i : bobot pada *input gate*

h_{t-1} : hasil *output* pada *time step* $t - 1$

x_t : *input* pada *time step* t

b_i : bias pada *input gate*

Selanjutnya memperbarui *cell state* yang lama (c_{t-1}) ke *cell state* yang baru (c_t) dengan persamaan *Cell State* (*final cell state*) sebagai berikut :

$$c_t = f_t \times c_{t-1} + i_t \times c_t^{\sim} \quad (2.17)$$

Pada *output gate* hasilnya akan berdasarkan *cell state*. Dimulai dengan menjalankan lapisan *sigmoid* yang menentukan bagian mana dari *cell state* yang akan dihasilkan. Kemudian, memasukkan *cell state* melalui $\tan(h)$ agar nilainya berada pada rentang -1 hingga 1) dan mengalikannya dengan *output gate* *sigmoid*, sehingga hanya menghasilkan bagian yang dipilih.

Berikut persamaan *Output Gate* :

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.18)$$

$$h_t = o_t \times \tanh(c_t) \quad (2.19)$$

Keterangan :

o_t : *output gate*

h_t : *hidden state*

σ : *sigmoid function*

W_o : bobot pada *output gate*

h_{t-1} : hasil *output* pada *time step* $t - 1$

x_t : *input* pada *time step* t

b_o : bias pada *output gate*

2.4 AKURASI MODEL

Akurasi model diukur menggunakan metrik akurasi dan laporan klasifikasi memberikan informasi lebih rinci tentang performa model dengan menggunakan data pengujian untuk memvalidasi kinerja model (Suryantara, 2024). Metode peramalan tidak ada yang dapat meramalkan dengan tepat keadaan di masa yang akan datang. Oleh karena itu, setiap metode peramalan menghasilkan kesalahan atau galat. Jika galat yang dihasilkan semakin kecil, maka hasil peramalan akan semakin mendekati tepat. Untuk mengukur kinerja model peramalan terdapat beberapa indikator analisis kesalahan.

2.4.1 *Root Mean Square Error (RMSE)*

Metode akar kuadrat rata rata (RMSE) adalah akar dari MSE yang mana memberikan nilai akurasi dan presisi pada peramalan. RMSE selalu bersifat non-negatif dan nilai 0 berarti menandakan bahwa sebuah hasil perkiraan dari model tidak terdapat kesalahan. Secara singkat, semakin rendah nilai RMSE maka model tersebut semakin baik dan semakin tinggi nilai RMSE maka model tersebut semakin buruk (Hendra et al., 2023).

Persamaan RMSE sebagai berikut :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (|y_i - y'_i|)^2} \quad (2.20)$$

Keterangan :

n : jumlah data

y_i : nilai aktual ke-i

y'_i : nilai ramalan ke -i

2.4.2 *Mean Absolute Error (MAE)*

Mean Absolute Error (MAE) adalah salah satu metode evaluasi yang digunakan untuk mengukur tingkat keakuratan model peramalan. Nilai MAE menunjukkan rata-rata kesalahan absolut antara hasil peramalan/prediksi dengan nilai rill (Suryanto & Muqtadir, 2019).

Bentuk persamaan MAE sebagai berikut :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - y'_i| \quad (2.21)$$

Keterangan :

n : jumlah data

y_i : nilai aktual ke-i

y'_i : nilai ramalan ke -i

2.5 FAKTOR IKLIM

Iklim adalah kelanjutan dari hasil pencatatan unsur cuaca dari hari ke hari dalam waktu yang lama, sehingga disebut sebagai rata-rata dari unsur cuaca secara umum. Iklim bersifat stabil bila dibandingkan dengan cuaca. Perubahan iklim berlangsung dalam periode yang lama dan meliputi area yang sangat luas. Matahari merupakan kendali utama sistem iklim. Iklim dipengaruhi oleh berbagai faktor, seperti curah hujan, kelembapan udara (relatif), suhu udara, radiasi matahari, dan kecepatan angin. (Sujalu et al.,2022). Namun, dalam penelitian ini, hanya tiga faktor utama yang digunakan, yaitu curah hujan, suhu udara, dan kelembapan udara relatif, karena faktor-faktor tersebut memiliki pengaruh langsung terhadap pertumbuhan padi dan ketersediaan air di lahan pertanian

2.5.1 Curah Hujan

Curah hujan merupakan banyaknya air hujan yang tidak mengalir, tidak menguap dan tidak meresap ke dalam tanah pada suatu wilayah. Curah hujan pada suatu tempat berbeda-beda, tergantung pada ketinggian daerah tersebut, besarnya curah hujan suatu wilayah diukur setiap 3 jam sekali dalam satuan milimeter (mm) (Seprima & Defrianto, 2020).

Tabel 2.1. Kategori intensitas curah hujan menurut BMKG

No	Jumlah Curah Hujan	Kategori Curah Hujan
1	0 – 0,4 mm/hari	Berawan
2	0,5 – 19,9 mm/hari	Hujan Ringan
3	20 – 49,9 mm/hari	Hujan Sedang
4	50 – 99,9 mm/hari	Hujan Lebat
5	100 – 150 mm/hari	Hujan Sangat Lebat
6	> 150 mm/hari	Hujan Ekstrem

Salah satu alat pengukuran curah hujan ialah dengan citra radar. Dengan mempertimbangkan seberapa besar pancaran energi radar yang dipantulkan kembali oleh butiran air di dalam awan, dan digambarkan dengan produk reflektivitas yang memiliki besaran satuan dBZ (*decibel*), citra radar cuaca menunjukkan potensi intensitas curah hujan (*presipitasi*).

2.5.2 Kelembapan Udara Relatif

Kelembapan udara adalah kondisi yang mana terdapat banyak uap air di udara. Kelembapan dapat dikatakan tinggi ketika ada banyak uap air di udara. Uap air dapat menyebabkan tingginya jumlah air di udara. Kuantitas uap air di udara sangat dipengaruhi oleh suhu sekitar (Sari et al., 2020). Uap air di udara dapat berubah menjadi cair atau padat, dan pada akhirnya turun ke bumi sebagai hujan. Jika kelembapan udara relatif tinggi, maka udara dalam keadaan basah atau mengandung banyak uap air. Nilai kelembapan udara dapat dinyatakan dengan berbagai ukuran, salah satunya adalah dengan menggunakan kelembapan relatif (nisbi) (Fadholi, 2023).

Kelembapan relatif adalah perbandingan antara jumlah uap air yang ada di udara dengan jumlah maksimum uap air yang terkandung pada udara di suatu wilayah, dapat dirumuskan dengan persamaan:

$$Rh = \frac{e}{e_m} \times 100\% \quad (2.22)$$

Keterangan :

Rh : Kelembapan udara relatif (%)

e : tekanan uap air pada saat pengukuran (mb)

e_m : tekanan uap air maksimum yang dapat dicapai pada suhu udara dan tekanan udara saat pengukuran

2.5.3 Suhu Udara

Suhu udara adalah keadaan panas atau dinginnya udara. Alat untuk mengukur suhu udara atau derajat panas disebut termometer. Biasanya pengukuran dinyatakan dalam skala *Celcius* (C), *Reamur* (R), dan *Fahrenheit* (F). Suhu udara tertinggi dimuka bumi adalah di daerah tropis (sekitar ekuator) dan makin ke kutub semakin dingin. Sebagai contoh pada saat mendaki gunung, suhu udara akan terasa semakin dingin seiring dengan bertambahnya ketinggian. Setiap kenaikan bertambah 100 meter maka suhu akan berkurang (turun) rata-rata 0,6 °C. Penurunan suhu semacam ini disebut gradien temperatur vertikal atau *lapse rate*. Pada udara kering, *lapse rate* adalah 1 °C (Winarno et al., 2019).

2.6 POLA TANAM PADI SAWAH DAN KALENDER TANAM PADI

Dalam siklus pertanian terdapat 2 fase yang berpengaruh pada produktivitas sistem pertanian yaitu masa tanam dan masa bera. Masa Tanam merujuk pada waktu tertentu yang ditentukan untuk memulai penanaman. Masa Bera adalah periode di mana tanah tidak ditanami, yang penting untuk menjaga kesuburan tanah dan menghindari kelelahan tanah. Dalam konteks pertanian berkelanjutan, masa bera memungkinkan pemulihan nutrisi tanah dan mencegah penurunan produktivitas (Banjarnahor & Simanjuntak, 2015).

Kesesuaian lahan adalah tingkat kecocokan suatu bidang lahan untuk penggunaan tertentu. Dalam menilai kesesuaian lahan ada beberapa cara, antara lain dengan perkalian parameter, penjumlahan, atau menggunakan hukum minimum yaitu mencocokkan (*matching*) antara kualitas lahan sebagai parameter dengan kriteria kelas kesesuaian lahan yang telah disusun berdasarkan persyaratan penggunaan atau persyaratan tumbuh tanaman atau komoditas lainnya yang dievaluasi. Berdasarkan penilaian yang dilakukan didapatkan tabel kesetaraan iklim yang merujuk pada penilaian kesesuaian lahan dapat dilihat pada Tabel 2.3 (Djaenudin et al., 2011).

Tabel 2.2 Tabel kesetaraan iklim

Komoditas	Curah Hujan (mm/hari)	Suhu Udara (°C)	Kelembapan Udara (%)
Padi Sawah	5,7-16,7	24-29	33-90

Proses penyusunan kalender tanam dengan prosedur setidaknya dua dari tiga variabel memenuhi kriteria agar tanggal tanam dapat dianggap optimal. Jika dua parameter dari ketiga variabel tersebut memenuhi kriteria yang telah ditentukan, maka tanggal tersebut akan dimasukkan dalam kalender tanam sebagai waktu yang ideal untuk melakukan penanaman padi. Sebaliknya jika hanya satu variabel yang memenuhi syarat, maka tanggal tersebut akan dianggap sebagai masa istirahat tanam.

Dengan kesetaraan iklim dalam penentuan pola tanam padi sawah dapat menjadi acuan pengaturan waktu tanam yang sesuai dengan kondisi iklim yang ada. Estimasi waktu tanam dikemas dalam bentuk kalender tanam sebagai panduan bagi petani.

2.7 THE POWER LARC PROJECT NASA

National Aeronautics and Space Administration (NASA) melalui program penelitian Ilmu Bumi, telah lama mendukung sistem satelit dan penelitian yang menyediakan data penting untuk studi proses iklim. Data-data ini mencakup perkiraan jangka panjang rata-rata iklim dari jumlah meteorologi dan intensitas energi matahari permukaan. Selain itu, nilai harian rata-rata dari data meteorologi dan matahari dasar disediakan dalam format deret waktu. Satelit dan produk berbasis model ini telah terbukti cukup akurat untuk memberikan data sumber daya matahari dan meteorologi yang andal di wilayah di mana pengukuran lokal jarang atau tidak ada. Produk ini menawarkan dua fitur unik, datanya bersifat global dan umumnya berdekatan dalam waktu. Dua karakteristik penting ini cenderung menghasilkan arsip data yang sangat besar yang dapat mengintimidasi pengguna, terutama mereka yang memiliki sedikit pengalaman atau sumber daya untuk menjelajahi dataset ini (White et al., 2008).

GPM (*Global Precipitation Measurement*) merupakan jaringan satelit internasional yang menyediakan pengamatan global untuk waktu yang akan datang terkait hujan dan salju. Konsep GPM berpusat pada penyebaran satelit yang membawa sistem radar canggih untuk mengukur curah hujan dari luar angkasa. *Global Surface Temperature Analysis* (GISTEMP) merupakan salah satu dataset suhu permukaan global yang komprehensif yang digunakan untuk memantau variabilitas dan tren suhu global dan regional. Sistem *Goddard Earth Observing System Forward Processing* (GEOS-FP) merupakan model penelitian yang dikelola oleh Asimiliasi Global Nasa untuk menghitung kelembapan relatif. Kelembapan dihitung dengan menggunakan kombinasi suhu dekat permukaan dan media uap air.

BAB III METODE PENELITIAN

3.1 DATA DAN VARIABEL PENELITIAN

Penelitian ini menggunakan data sekunder yang diperoleh dari Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) dapat diakses melalui <https://dataonline.bmkg.go.id/> dan *power larc nasa* dapat diakses melalui situs online <https://power.larc.nasa.gov/>. Data yang digunakan berada pada titik koordinat lintang 5,522 dan bujur 95,417 dengan jumlah data sebanyak 5.053 observasi pada periode waktu yaitu data harian dari 1 Januari 2011 hingga 31 Oktober 2024.

Adapun variabel-variabel yang digunakan dalam penelitian ini dapat dilihat pada Tabel 3.1.

Tabel 3.1. Variabel penelitian

Variabel	Keterangan	Satuan	Tipe Data
Y_1	Curah Hujan	mm/hari	Rasio
Y_2	Kelembapan Udara (relatif)	%	Rasio
Y_3	Suhu Udara	°C	Interval

3.2 PROSEDUR ANALISIS DATA


Analisis data diperlukan prosedur sebagai pedoman dalam proses penelitian. *Software* yang digunakan untuk membantu penelitian ini yaitu *Python 3.10.0* yang digunakan untuk menganalisis data. Adapun langkah-langkah yang dilakukan dalam penelitian ini adalah sebagai berikut:

1. Mengunduh data curah hujan, suhu udara dan kelembapan udara relatif dari NASA yang diunduh dari situs <https://power.larc.nasa.gov/>.
2. Mengunduh data curah hujan, suhu udara dan kelembapan udara relatif dari BMKG yang diunduh dari situs <https://dataonline.bmkg.go.id/>.
3. Melakukan penginputan data pada *Python 3.10.0* dan *cleaning* data yang akan digunakan untuk analisis dengan melakukan imputasi *mean* pada variabel yang memiliki data kosong
4. Melakukan eksplorasi data untuk memahami karakteristik data yang disajikan dalam bentuk tabel ringkasan statistik, mengidentifikasi pola dan tren dengan visualisasi plot deret waktu, serta menemukan anomali atau *outlier*

5. Membagi data menjadi data pelatihan (*train*) dan data pengujian (*test*). Data *train* digunakan untuk melatih model, sedangkan data *test* untuk menguji kinerja model. Tujuan membagi data untuk menghindari *overfitting* yang mana model hanya bekerja dengan baik pada data yang dilatih, tetapi tidak mampu melakukan generalisasi pada data baru. Adapun skenario pembagian data yaitu 70:30, 80:20, dan 90:10.
6. Membentuk model *Holt-Winters*. Dengan menentukan nilai parameter pemulusan α , β , dan γ yang paling optimal dengan perhitungan pada persamaan 2.1 hingga 2.14
7. Membangun arsitektur LSTM. Konfigurasi pada algoritma LSTM dengan perhitungan pada persamaan 2.15 hingga 2.19, dan akan menggunakan *epoch* 100 dan *batch size* 32, serta 4 *layer* dengan 3 *layer* LSTM dan 1 *dense layer*
8. Melakukan peramalan dengan kedua metode yaitu *Holt-Winters* dan LSTM
9. Melakukan evaluasi kinerja pada setiap metode peramalan dengan menghitung nilai RMSE pada persamaan 2.20 dan menghitung MAE pada persamaan 2.21
10. Pemilihan model peramalan terbaik dengan melihat RMSE dan MAE yang paling kecil
11. Melakukan peramalan 365 hari periode yang akan datang dengan model dan sumber data dengan nilai RMSE dan MAE terkecil.
12. Membentuk kalender tanam dengan melihat curah hujan, kelembapan udara relatif dan suhu udara yang baik untuk masa tanam padi sawah pada tabel 2.3 berdasarkan data hasil peramalan.
13. Membuat kesimpulan terhadap hasil penelitian yang telah dilakukan dan memberikan saran kepada penulis selanjutnya serta pemerintah.

3.3 DIAGRAM ALIR PENELITIAN

Prosedur analisis data yang dilakukan dapat dilihat pada Gambar 3.1 berikut



Gambar 3.2 Diagram alir penelitian

BAB IV HASIL DAN PEMBAHASAN

4.1 PERSIAPAN DATA

Persiapan data merupakan langkah penting dalam analisis data untuk memastikan bahwa data yang digunakan sudah terstruktur dan siap untuk diproses lebih lanjut. Dari data yang digunakan dilakukan *cleaning data* untuk memastikan data yang digunakan tidak mengandung nilai yang hilang (*missing value*). Pada penelitian ini dilakukan proses imputasi *missing value* dengan menggunakan metode *mean imputation* dengan mengganti semua data kosong dengan nilai mean pada setiap variabel.

4.2 ANALISIS DESKRIPTIF

Analisis deskriptif bertujuan untuk memahami karakteristik data sebelum dilakukan pemodelan

4.2.1 Ringkasan Statistik

Hasil ringkasan statistik sebelum dan sesudah imputasi untuk data BMKG dan data NASA dapat dilihat pada Lampiran 2. Berikut adalah ringkasan statistik variabel penelitian:

Tabel 4.1 Ringkasan statistik setiap variabel penelitian sebelum imputasi

Data	Keterangan	Curah Hujan	Kelembapan Udara (relatif)	Suhu Udara
BMKG	Jumlah Data	3.478	4.808	4.808
	Jumlah Data Kosong	1.575	245	245
	Minimum	0	46	23,1
	Q1	0	75	26,5
	Median	0,8	80	27,3
	Mean	8,78	78,90	27,36
	Q3	8	84	28,2
	Maksimum	200	98	33
	Standar Deviasi	19,21	7,41	1,23

Data	Keterangan	Curah Hujan	Kelembapan Udara (relatif)	Suhu Udara
NASA	Jumlah Data	5.050	5.050	5.050
	Jumlah Data Kosong	3	3	3
	Minimum	0	63,69	24,37
	Q1	0,74	76,25	26,41
	Median	2,67	79,25	26,95
	Mean	6,19	79,18	26,99
	Q3	7,06	82,25	27,55
	Maksimum	149,12	92	30,07
	Standar Deviasi	10,16	4,46	0,83

Tabel 4.2 Ringkasan statistik setiap variabel penelitian setelah imputasi

Data	Keterangan	Curah Hujan	Kelembapan Udara (relatif)	Suhu Udara
BMKG	Jumlah Data	5.053	5.053	5.053
	Minimum	0	46	23,1
	Q1	0	75	26,6
	Median	6,5	79	27,36
	Mean	8,78	78,90	27,36
	Q3	8,78	84	28,1
	Maksimum	200	98	33
	Standar Deviasi	15,94	7,22	1,20
NASA	Jumlah Data	5.053	5.053	5.053
	Minimum	0	63,69	24,37
	Q1	0,74	76,25	26,41
	Median	2,67	79,25	26,95
	Mean	6,19	79,18	26,99
	Q3	7,06	82,25	27,55
	Maksimum	149,12	92	30,07
	Standar Deviasi	10,16	4,46	0,83

Tabel 4.1 menampilkan ringkasan statistik sebelum dilakukan imputasi. Pada dataset BMKG, variabel curah hujan memiliki jumlah data sebanyak 3.478 sedangkan variabel kelembapan udara relatif dan suhu udara masing-masing memiliki 4.808 data, hal ini menunjukkan adanya data yang hilang atau *missing values*. Nilai minimum

untuk variabel curah hujan adalah 0 mm/hari, yang mengindikasikan adanya hari-hari tanpa hujan selama periode pengamatan. Nilai maksimum yang tercatat mencapai 200 mm/hari, menunjukkan adanya kejadian curah hujan ekstrem. Median curah hujan yang bernilai 0 menunjukkan bahwa lebih dari separuh data memiliki curah hujan yang rendah atau bahkan tidak ada hujan sama sekali. Untuk kelembapan udara relatif, nilai minimum adalah 46% dan maksimum 98%, yang menunjukkan variabilitas kelembapan yang cukup besar. Rata-rata kelembapan udara sebesar 78,90%. Sedangkan untuk suhu udara, nilai minimum yang tercatat adalah 23,1°C dan maksimum 33°C, dengan rata-rata 27,3°C, menunjukkan bahwa suhu udara berada dalam rentang yang relatif stabil. Standar deviasi curah hujan yang tinggi (19,21) dibandingkan dengan kelembapan udara (7,41) dan suhu udara (1,23) menunjukkan adanya variabilitas yang lebih besar pada data curah hujan dibandingkan dengan dua variabel lainnya.

Sementara itu, pada dataset NASA sebelum dilakukan imputasi jumlah data yang tersedia untuk semua variabel lebih lengkap dengan total data sebanyak 5.050 pada setiap variabel atau hanya 3 data kosong. Curah hujan memiliki nilai minimum 0 dan maksimum sebesar 149,12 mm/hari, dengan rata-rata sebesar 6,19 mm/hari. Nilai median curah hujan yang rendah menunjukkan bahwa sebagian besar hari memiliki curah hujan rendah atau tanpa hujan, hal ini serupa dengan pola yang terlihat pada dataset BMKG. Untuk kelembapan udara relatif pada dataset NASA, nilai minimum sebesar 63,69% dan maksimum 92%. Suhu udara pada dataset NASA memiliki minimum 24,37°C dan maksimum 30,07°C, dengan rata-rata 26,99°C yang sedikit lebih rendah daripada rata-rata suhu pada data BMKG.

Tabel 4.2 menampilkan ringkasan statistik setelah dilakukan imputasi seluruh variabel memiliki jumlah data yang seragam yaitu 5.053. Pada data BMKG, standar deviasi setiap variabel menurun terutama curah hujan menjadi 15,94. Ini menunjukkan bahwa metode imputasi berhasil mengisi *missing values* dan mengurangi variasi ekstrem. Untuk proses analisis selanjutnya menggunakan dataset yang telah dilakukan proses imputasi. Analisis deskriptif yang digunakan dalam penelitian ini juga membuat kategori curah hujan yang diperoleh dari BMKG. Jumlah data berdasarkan kategori curah hujan pada setiap dataset ditampilkan pada tabel 4.3.


Tabel 4.3 Jumlah data berdasarkan kategori curah hujan

Data	Kategori Curah Hujan	Jumlah Data
BMKG	Berawan	1.708
	Hujan Ringan	2.888
	Hujan Sedang	300
	Hujan Lebat	127
	Hujan Sangat Lebat	26
	Hujan Ekstrem	4
NASA	Berawan	1.016
	Hujan Ringan	3.667
	Hujan Sedang	320
	Hujan Lebat	46
	Hujan Sangat Lebat	4
	Hujan Ekstrem	0


Tabel 4.3 menunjukkan bahwa dalam 14 tahun terakhir hujan ringan paling sering terjadi dengan jumlah 2.888 pada dataset BMKG dan 3667 pada dataset NASA.

4.2.2 Plot Deret Waktu

Plot deret waktu adalah visualisasi data untuk memahami pola data selama periode waktu tertentu.





Gambar 4.1 Plot deret waktu curah hujan sebelum imputasi





Gambar 4.2 Plot deret waktu curah hujan setelah imputasi

Dari gambar 4.1 terlihat bahwa terdapat *missing value* atau data kosong dengan terlihat adanya celah pada plot sebelum imputasi. Gambar 4.2 menampilkan deret waktu curah hujan dari 1 Januari 2011 hingga 31 Oktober 2024 berdasarkan dua sumber data yaitu BMKG dan NASA. Plot deret waktu curah hujan dihasilkan dengan pemrosesan yang terdapat pada lampiran 3. Secara umum, grafik menunjukkan pola fluktuasi curah hujan harian dengan variasi yang cukup besar. Kedua sumber data mencatat adanya periode curah hujan yang tinggi (outlier) di beberapa titik waktu. Grafik curah hujan dataset BMKG tampak memiliki puncak curah hujan yang lebih sering dibandingkan data dari NASA.




Gambar 4.3 Plot deret waktu kelembapan udara relatif sebelum imputasi




Gambar 4.4 Plot deret waktu kelembapan udara relatif setelah imputasi

Gambar 4.3 dan Gambar 4.4 merupakan plot deret waktu sebelum dan sesudah imputasi pada variabel kelembapan udara relatif, pada plot tersebut data kosong nya tidak terlihat dikarenakan hanya sebagian kecil dari jumlah seluruh data. Gambar 4.4 menunjukkan deret waktu kelembapan udara relatif berdasarkan data dari dua sumber yaitu BMKG dan NASA. Plot deret waktu kelembapan udara relatif dihasilkan dengan pemrosesan yang terdapat pada lampiran 3. Grafik tersebut menggambarkan fluktuasi kelembapan udara relatif secara harian dengan pola yang cukup seragam dan stabil di kedua data. Pola fluktuasi terlihat mirip di kedua sumber data, meskipun terdapat perbedaan kecil dalam intensitas dan keragaman datanya.



Gambar 4.5 Plot deret waktu suhu udara sebelum imputasi



Gambar 4.6 Plot deret waktu suhu udara setelah imputasi


Gambar 4.5 dan Gambar 4.6 merupakan plot deret waktu sebelum dan sesudah imputasi pada variabel suhu udara, pada plot tersebut data kosong nya tidak terlihat dikarenakan hanya sebagian kecil dari jumlah seluruh data. Gambar 4.6 menampilkan deret waktu suhu udara berdasarkan data harian dari dua sumber data yaitu BMKG dan NASA. Kedua grafik menunjukkan fluktuasi suhu udara dengan pola musiman yang cenderung stabil sepanjang waktu pengamatan. Secara umum, suhu udara berada pada rentang yang serupa di kedua data, meskipun terdapat sedikit variasi pola datanya. Pola fluktuasi variabel suhu udara terlihat jelas membentuk siklus musiman

4.2.3 Dekomposisi Deret Waktu

Dekomposisi deret waktu merupakan teknik statistik yang digunakan untuk memecah kumpulan data deret waktu menjadi komponen-komponen deret waktu dapat membantu memahami karakteristik data deret waktu. Plot dekomposisi dihasilkan dengan pemrosesan yang terdapat pada lampiran 4. Komponen-komponen ini biasanya meliputi :

1. Komponen *trend* merepresentasikan arah atau pola jangka panjang dalam data, yang mengindikasikan apakah data mengalami peningkatan, penurunan, atau tetap stabil seiring waktu.


2. Musiman (*seasonal*) menampilkan pola berulang dan teratur dalam data
3. Residual (sis) merupakan variasi acak atau ketidakaturan yang tersisa setelah menghilangkan *trend* dan komponen musiman. Pada pola residu dapat mengidentifikasi *outlier*.



Gambar 4.7 Dekomposisi deret waktu curah hujan

Gambar 4.7 menggambarkan dekomposisi data deret waktu curah hujan ke dalam empat komponen utama: plot deret waktu curah hujan, *trend*, *seasonal* (musiman), dan residual (sis). bagian pertama menunjukkan data asli curah hujan dari 1 Januari 2011 hingga 31 Oktober 2024 dari kedua sumber data. Terlihat ada fluktuasi pola curah hujan dari waktu ke waktu. Bagian kedua menunjukkan tren pada variabel curah hujan. Data BMKG menunjukkan tren yang lebih dinamis dengan puncak dan penurunan curah hujan yang tajam di beberapa tahun tertentu. Data NASA juga menunjukkan tren yang berubah, memiliki pola yang lebih stabil dan cenderung menurun pada tahun-tahun awal yaitu 2011 hingga 2014. Bagian ketiga, pola musiman terlihat cukup jelas di kedua dataset. Data BMKG menunjukkan pola yang lebih tajam pada bagian puncak musiman dibandingkan data NASA. Bagian keempat


memperlihatkan komponen residual, yang mencerminkan variasi acak atau ketidakteraturan yang tersisa setelah komponen tren dan musiman dihilangkan. Titik-titik residual yang tersebar menunjukkan adanya beberapa anomali. Hal ini menunjukkan data BMKG dan NASA terdapat perbedaan dalam detailnya, terutama pada nilai-nilai ekstrem.



Gambar 4.8 Dekomposisi deret waktu kelembapan udara relatif

Gambar 4.8 menunjukkan dekomposisi data deret waktu kelembapan. Pada bagian pertama menampilkan data asli kelembapan udara relatif menunjukkan fluktuasi yang signifikan dengan pola kombinasi antara tren, musiman, dan variasi acak. Fluktuasi ini cukup konsisten antara data BMKG dan NASA, meskipun terdapat beberapa perbedaan dalam variasinya. Bagian kedua menggambarkan tren kelembapan udara untuk kedua dataset. Data BMKG menunjukkan tren yang relatif stabil hingga awal tahun 2020 kemudian sedikit menurun menuju tahun 2024. Sementara itu, data NASA menunjukkan tren yang mirip tetapi dengan pola yang lebih halus dan lebih stabil. Bagian ketiga, komponen musiman sangat jelas terlihat dalam

kedua dataset. Pola musiman ini menunjukkan siklus kelembapan udara relatif yang berulang secara periodik setiap tahun. Pola komponen musiman pada dataset NASA lebih tajam dibandingkan dataset BMKG. Bagian terakhir menunjukkan komponen residual, yaitu variasi acak yang tidak dapat dijelaskan oleh tren atau pola musiman. Pada kedua dataset, residual menunjukkan fluktuasi yang cukup stabil juga terlihat beberapa outlier pada kelembapan udara relatif.




Gambar 4.9 Dekomposisi deret waktu suhu udara

Gambar 4.9 menunjukkan dekomposisi data deret waktu terkait suhu udara menggunakan dataset BMKG dan dataset NASA pada periode 1 Januari 2011 hingga 31 Agustus 2024. Bagian pertama menunjukkan data asli suhu udara dengan pola fluktuasi yang hampir mirip dan pola cenderung stabil sepanjang periode pengamatan. Pola tren menunjukkan perubahan jangka panjang dalam suhu udara. Data BMKG memperlihatkan sedikit kenaikan suhu udara secara bertahap hingga tahun 2016 sementara data NASA menunjukkan pola tren yang lebih bervariasi dengan fluktuasi yang meningkat pada akhir Oktober 2024. Plot ketiga adalah komponen musiman

menunjukkan pola berulang tahunan yang konsisten pada kedua dataset, dengan puncak suhu pada musim tertentu dan penurunan suhu di musim lainnya. Hal ini mengindikasikan pengaruh faktor iklim musiman yang dominan. Plot residual ini menggambarkan variasi acak yang tidak dijelaskan oleh tren dan musiman. Sebaran residual pada kedua dataset terlihat seragam.

4.2.4 Boxplot


Boxplot adalah salah satu teknik yang digunakan untuk analisis data eksploratif. Boxplot menggunakan lima ringkasan poin sebagai teknik standarnya yang mencakup nilai minimum, maksimum kuartil atas dan bawah serta median. Boxplot dihasilkan dengan pemrosesan yang terdapat pada lampiran 5.



Gambar 4.10 Boxplot curah hujan

Gambar 4.10 menggambarkan distribusi curah hujan harian dari dua dataset, yaitu BMKG dan NASA dalam rentang waktu 1 Januari 2011 hingga 31 Oktober 2024. Pada sumbu X ditampilkan pembagian data berdasarkan tahun sementara sumbu Y menunjukkan nilai curah hujan harian dalam satuan milimeter. Secara visual, distribusi curah hujan dari kedua dataset memiliki karakteristik yang serupa, namun terdapat perbedaan dalam detail pola distribusi.


Pada kedua grafik, nilai median curah hujan (garis horizontal di tengah kotak) relatif rendah di sebagian besar tahun, menunjukkan bahwa curah hujan harian pada umumnya berada di kisaran rendah hingga sedang. Namun terdapat sejumlah outlier (ditunjukkan oleh titik-titik di atas whisker) yang mengindikasikan kejadian curah hujan tinggi pada beberapa hari tertentu. Jumlah dan sebaran outlier tampak berbeda antara dataset BMKG dan NASA, dengan dataset BMKG cenderung menunjukkan lebih banyak outlier di beberapa tahun, terutama pada tahun tertentu seperti 2016 dan 2020. Pada rentang antar-kuartil (IQR) dari dataset NASA terlihat sedikit lebih lebar dibandingkan BMKG seperti 2016, 2017 dan 2018.



Gambar 4.11 Boxplot kelembapan udara relatif

Gambar 4.11 menunjukkan boxplot kelembapan udara relatif harian berdasarkan dataset BMKG dan NASA untuk periode 1 Januari 2011 hingga 31 Agustus 2024. Sumbu X menunjukkan pembagian data berdasarkan tahun sementara sumbu Y menggambarkan persentase kelembapan udara. Distribusi data dari kedua dataset menunjukkan pola yang konsisten dengan median kelembapan udara yang relatif stabil di sebagian besar tahun. Rentang antar-kuartil (IQR) terlihat relatif sempit pada sebagian besar tahun untuk kedua dataset, yang mengindikasikan variabilitas kelembapan udara yang rendah di sekitar median. Namun, terdapat beberapa outlier

(ditandai oleh titik-titik di luar whisker), yang menunjukkan kondisi kelembapan udara ekstrem pada hari tertentu. Dataset NASA menunjukkan distribusi yang sedikit lebih lebar pada beberapa tahun seperti pada 2015 dan 2020 dibandingkan dengan BMKG.



Gambar 4.12 Boxplot suhu udara

Gambar 4.12 menunjukkan boxplot distribusi suhu udara harian berdasarkan dataset BMKG dan NASA untuk periode 1 Januari 2011 hingga 31 Agustus 2024. Sumbu X menunjukkan data yang dikelompokkan berdasarkan tahun, sedangkan sumbu Y menggambarkan nilai suhu udara. Secara umum, distribusi suhu udara pada kedua dataset menunjukkan pola yang relatif stabil sepanjang periode waktu yang diamati. Perbandingan antara kedua dataset menunjukkan bahwa pola umum suhu udara dari BMKG dan NASA serupa, meskipun terdapat perbedaan kecil dalam variasi data, seperti pada tahun 2014, 2016 dan 2023, di mana boxplot dataset NASA tampak sedikit lebih lebar.

4.3 PEMBAGIAN DATA PELATIHAN DAN PENGUJIAN

Setelah data kosong terisi, selanjutnya data dibagi menjadi dua bagian yaitu data pelatihan dan data pengujian. Data pelatihan digunakan untuk merancang model peramalan, dan data uji digunakan untuk menguji model yang diperoleh. Pembagian data berdasarkan proporsi data 70% data pelatihan dan 30% data pengujian dari total

keseluruhan data sebanyak 5.053 baris data. Sehingga diperoleh data pelatihan 3.537 data yaitu dari data 1 Januari 2011 sampai 6 September 2020. Data pengujian sebanyak 1.516 data yaitu dari data 7 September 2020 sampai 31 Oktober 2025. Sebagai pembanding lainnya juga digunakan pembagian dengan proporsi data pelatihan sebesar 80% dan data pengujian sebesar 20%, serta proporsi data pelatihan 90% dan data pengujian 10%. Hal ini dilakukan untuk mengetahui dampak perbedaan pembagian data pada hasil peramalan.

4.4 HOLT-WINTERS

4.4.1 Perancangan Model Holt-Winters

Pada gambar dekomposisi deret waktu menunjukkan bahwa semua plot musiman bersifat konstan maka peramalan model Holt-Winters metode aditif pada semua variabel. Sebelum melakukan peramalan perlu dilakukan inisialisasi nilai awal untuk panjang periode *seasonal*. Inisialisasi untuk panjang periode ditentukan sebesar 365 dikarenakan data deret waktu harian.

Nilai parameter pemulusan untuk level (α), parameter pemulusan untuk tren (β), dan parameter pemulusan untuk *seasonal* (γ) ditentukan yang paling optimal dengan memanfaatkan bantuan *python*. Berdasarkan untuk menentukan parameter yang optimal dengan menggunakan data pelatihan berikut skenario untuk *Holt-Winters* seperti ditampilkan pada Tabel 4.4.

Tabel 4.4 Model *Holt-Winters* pada setiap skenario pembagian data

Data	Variabel	Pembagian Data	α	β	γ	s
BMKG	Curah Hujan	70 : 30	0,033	$6,96 \times 10^{-10}$	0,055	365
		80 : 20	0,099	0,004	0,070	365
		90 : 10	0,056	0,0004	0,830	365
	Kelembapan	70 : 30	0,331	$9,89 \times 10^{-5}$	0,002	365
		80 : 20	0,340	0,001	0,009	365
		90 : 10	0,365	0,001	0,017	365
	Suhu	70 : 30	0,282	$4,91 \times 10^{-9}$	$3,36 \times 10^{-7}$	365
		80 : 20	0,289	$7,71 \times 10^{-8}$	$7,77 \times 10^{-8}$	365
		90 : 10	0,295	$4,26 \times 10^{-9}$	$1,01 \times 10^{-7}$	365
NASA	Curah Hujan	70 : 30	0,437	0,022	0,299	365
		80 : 20	0,389	0,013	0,078	365
		90 : 10	0,355	0,006	0,085	365

Data	Variabel	Pembagian Data	α	β	γ	s
NASA	Kelembapan	70 : 30	0,501	$6,95 \times 10^{-5}$	6,001	365
		80 : 20	0,498	$2,73 \times 10^{-5}$	$6,96 \times 10^{-5}$	365
		90 : 10	0,493	$8,89 \times 10^{-5}$	0,0002	365
	Suhu	70 : 30	0,619	$1,57 \times 10^{-9}$	$1,22 \times 10^{-7}$	365
		80 : 20	0,623	$2,59 \times 10^{-9}$	$3,72 \times 10^{-7}$	365
		90 : 10	0,604	$1,32 \times 10^{-9}$	$6,02 \times 10^{-7}$	365

Pada Tabel 4.4, periode *seasonal* (s), parameter pemulusan untuk level (α), parameter pemulusan untuk *trend* (β), dan parameter pemulusan untuk *seasonal* (γ) bernilai berbeda untuk semua jenis skenario yang dapat dilihat pada Lampiran 3 hingga Lampiran 8. Hal ini terjadi karena memang nilai-nilai tersebut merupakan nilai paling optimal yang dapat diperoleh dan hasil tingkat akurasi yang dihasilkan nantinya berbeda karena perbedaan pembagian data pelatihan dan pengujian yang dilakukan.

4.4.2 Peramalan dengan *Holt-Winters*

Setelah diperoleh nilai optimal parameter pemulusan untuk level (α), parameter pemulusan untuk *trend* (β), dan parameter pemulusan untuk *seasonal* (γ), maka dilakukan peramalan dari data pelatihan dan di uji terhadap data pengujian dengan melakukan peramalan untuk beberapa periode kedepan terhadap data pengujian. Dari hasil peramalan tersebut dapat dihitung nilai akurasi yang dihasilkan. Pada tabel 4.5 menampilkan nilai akurasi yang dihasilkan untuk data pelatihan setiap model yang diperoleh dari Tabel 4.4.

Tabel 4.5 Tingkat akurasi data pelatihan Model *Holt-Winters*

Data	Variabel	Ukuran Akurasi	Proporsi Data Pelatihan		
			70%	80%	90%
BMKG	Curah Hujan	RMSE	19,13	18,14	13,95
		MAE	11,38	11,35	7,38
	Kelembapan Udara Relatif	RMSE	10,11	6,47	11,01
		MAE	8,59	5,07	9,45
	Suhu Udara	RMSE	1,46	1,09	1,20
		MAE	1,22	0,86	0,92
NASA	Curah Hujan	RMSE	11,75	11,31	10,58
		MAE	7,85	6,55	5,63
	Kelembapan Udara Relatif	RMSE	4,88	5,38	5,59
		MAE	3,85	4,48	4,66
	Suhu Udara	RMSE	0,83	0,77	0,84
		MAE	0,66	0,61	0,84

Diketahui bahwa tingkat akurasi terbaik yaitu pada data NASA dengan pembagian data 90:10 (data pelatihan 90% dan data pengujian 10% dari jumlah dataset) untuk variabel curah hujan, kelembapan udara relatif pembagian data 70:30, pembagian data 80 : 20 untuk variabel suhu udara. Variabel curah hujan dengan nilai RMSE 10,58 dan MAE 5,63, variabel kelembapan udara relatif dengan nilai RMSE 4,88 dan MAE sebesar 3,85, dan variabel suhu udara dengan nilai RMSE 0,83 dan MAE 0,66 yang dapat dilihat pada Lampiran 3 hingga Lampiran 8.

4.5 LONG-SHORT TERM MEMORY (LSTM)

4.5.1 Perancangan Model Long-Short Term Memory (LSTM)

Metode LSTM digunakan dalam penelitian ini untuk melakukan peramalan pada variabel curah hujan, suhu udara, dan kelembapan udara relatif. Setiap variabel diramalkan secara terpisah, sehingga model dapat menangkap pola untuk masing-masing variabel. Setelah pembagian data, data pelatihan akan digunakan untuk menguji model LSTM. Selanjutnya dilakukan standarisasi data agar hasil prediksi model LSTM stabil terutama jika terdapat outlier juga beberapa algoritma bekerja lebih efektif Ketika input memiliki skala yang lebih beragam.

Model LSTM yang digunakan memiliki empat lapisan utama, dengan beberapa lapisan dropout di antaranya untuk mengurangi risiko *overfitting*. Lapisan-lapisan ini memungkinkan model mempelajari pola dalam data secara bertahap, dari pola jangka pendek hingga pola yang lebih kompleks dan berskala panjang. Optimisasi model dilakukan menggunakan *Adam optimizer*, sebuah algoritma optimasi berbasis *gradient descent* yang mempercepat proses pelatihan dengan penyesuaian *learning rate* secara adaptif, sehingga hasilnya lebih stabil. Untuk mencegah *overfitting* lebih lanjut, diterapkan teknik *early stopping* yang akan menghentikan pelatihan secara otomatis ketika tidak ada perbaikan pada performa model. Model dilatih selama 100 epoch, yang dipilih untuk memberikan waktu yang cukup bagi model dalam mempelajari pola data tanpa menyebabkan *overfitting*. Penggunaan *batch size* sebesar 32 dipilih karena ukuran ini memberikan keseimbangan yang baik antara kecepatan pelatihan dan akurasi, serta memungkinkan model untuk belajar dengan baik dari data. Sedangkan *validation split* sebesar 0,2 digunakan agar 20% dari data *training* dialokasikan untuk

validasi, yang membantu dalam memantau performa model dan menghindari overfitting yang dapat dilihat pada Lampiran 9.

4.5.2 Peramalan dengan *Long-Short Term Memory* (LSTM)

Model yang diperoleh juga diuji terhadap data pengujian dengan melakukan peramalan untuk beberapa periode kedepan terhadap data pengujian. Dari hasil peramalan tersebut dapat dihitung nilai akurasi yang dihasilkan. Pada tabel 4.6 menampilkan nilai akurasi yang dihasilkan model dengan setiap data pelatihan.

Tabel 4.6 Tingkat akurasi data pelatihan Model *LSTM*

Data	Variabel	Ukuran Akurasi	Proporsi Data Pelatihan		
			70%	80%	90%
BMKG	Curah Hujan	RMSE	0,092	0,082	0,064
		MAE	0,051	0,046	0,040
	Kelembapan Udara Relatif	RMSE	0,099	0,099	0,103
		MAE	0,076	0,076	0,078
	Suhu Udara	RMSE	0,090	0,086	0,090
		MAE	0,069	0,066	0,070
NASA	Curah Hujan	RMSE	0,071	0,067	0,057
		MAE	0,042	0,037	0,033
	Kelembapan Udara Relatif	RMSE	0,113	0,113	0,107
		MAE	0,087	0,087	0,083
	Suhu Udara	RMSE	0,080	0,080	0,080
		MAE	0,063	0,063	0,064

Diketahui nilai akurasi terbaik pada sumber data NASA dengan pembagian data 90:10 untuk variabel curah hujan dan kelembapan udara relatif, pembagian data 80 : 20 (data pelatihan 80% dan data pengujian 20% dari jumlah dataset) untuk variabel suhu udara. Variabel curah hujan dengan nilai RMSE 0,057 dan MAE 0,033, variabel kelembapan udara relatif dengan nilai RMSE 0,107 dan MAE sebesar 0,083, dan variabel suhu udara dengan nilai RMSE 0,80 dan MAE 0,064 yang dapat dilihat pada Lampiran 10 hingga Lampiran 15.

4.6 PEMILIHAN MODEL TERBAIK

Pemilihan model terbaik dilakukan dengan membandingkan performa dua metode peramalan, yaitu Holt-Winters dan Long Short-Term Memory (LSTM) terhadap variabel. Model-model yang diperoleh dievaluasi berdasarkan tingkat akurasi prediksi yang diukur menggunakan RMSE dan MAE dengan setiap skenario pembagian data yang telah dilakukan pada tahapan sebelumnya. Berdasarkan tingkat


akurasi yang ditampilkan pada Tabel 4.5 dan Tabel 4.6 dapat diketahui model terbaik atau model dengan nilai RMSE dan MAE paling rendah pada model LSTM dengan pembagian data 90:10 dikarenakan terdapat 2 variabel yang memiliki kinerja model terbaik pada pembagian data tersebut. Model dengan tingkat akurasi terbaik ditampilkan pada tabel 4.7.

Tabel 4.7 Model tingkat akurasi terbaik

Model	Variabel	Ukuran Kinerja Model	
		RMSE	MAE
LSTM 90:10	Curah Hujan	0,057	0,033
	Kelembapan Udara Relatif	0,107	0,083
	Suhu Udara	0,080	0,064

4.7 PERAMALAN PERIODE SELANJUTNYA

Berikut ditampilkan hasil peramalan terhadap curah hujan, suhu udara, dan kelembapan udara relatif pada data NASA untuk 365 hari mendatang dengan menggunakan model LSTM dengan pembagian data 90 : 10 yang merupakan model terbaik.



Gambar 4.13 Hasil peramalan curah hujan 365 hari selanjutnya

Gambar 4.13 menampilkan data historis (garis biru) dan hasil peramalan (garis merah) menggunakan model LSTM dengan standarisasi data. Data historis dari tahun 2011 hingga Oktober 2024 menunjukkan fluktuasi yang tinggi dengan beberapa lonjakan, yang mencerminkan variabel curah hujan yang kompleks. Hasil peramalan pada 1 November 2024 hingga 31 Oktober 2025 menunjukkan pola yang mengikuti tren historis dengan fluktuasi yang lebih terkendali, menandakan bahwa model LSTM


berhasil menangkap pola utama dalam data historis. Stabilitas peramalan tersebut menunjukkan efektivitas penggunaan standarisasi dalam meningkatkan kinerja model dengan memastikan data berada pada skala yang optimal untuk proses pembelajaran.

Berdasarkan hasil peramalan curah hujan dibentuk kategori curah hujan sesuai dengan klasifikasi dari BMKG untuk melihat distribusi curah hujan pada 365 hari selanjutnya. Jumlah data setiap kategori curah hujan ditampilkan pada tabel 4.8.

Tabel 4.8 Kategori curah hujan hasil peramalan

Kategori Curah Hujan	Jumlah Data
Berawan	0
Hujan Ringan	362
Hujan Sedang	3
Hujan Lebat	0
Hujan Sangat Lebat	0
Hujan Ekstrem	0


Berdasarkan tabel 4.8 dalam rentang waktu november 2024 hingga oktober 2025 sebagian besar menunjukkan kategori hujan ringan terjadi sebanyak 362 hari yaitu rentang 0,5 mm/hari – 19,9 mm/hari dan hujan sedang terjadi selama 3 hari yaitu pada rentang 20 mm/hari – 49,9 mm/hari. Hasil menunjukkan bahwa di Aceh Besar pada satu tahun mendatang didominasi oleh curah hujan dengan intensitas rendah.



Gambar 4.14 Hasil peramalan kelembapan udara relatif 365 hari selanjutnya

Gambar 4.14 menampilkan hasil peramalan kelembapan udara relatif yang dihasilkan oleh model LSTM pada 1 November 2024 hingga 31 Oktober 2025 menunjukkan pola musiman dan tren yang konsisten dengan data historis dan dengan

sedikit penurunan dari kelembapan rata rata. Secara visual, model berhasil mempertahankan karakteristik dari data historis dalam peramalan.



Gambar 4.15 Hasil peramalan suhu udara 365 hari selanjutnya

Gambar 4.15 menampilkan peramalan suhu udara menunjukkan pola serupa dengan pola musiman yang stabil, dan adanya potensi peningkatan fluktuasi kenaikan suhu udara di masa yang akan datang. Secara visual, grafik ini menggambarkan bagaimana pola historis digunakan untuk memperkirakan tren masa depan, dengan indikasi bahwa fluktuasi akan terus berlanjut dalam periode yang diprediksi.

4.8 PENYUSUNAN KALENDER TANAM

Kalender tanam disesuaikan berdasarkan klasifikasi kesesuaian curah hujan, suhu udara dan kelembapan udara relatif sebagai parameter utama yang memengaruhi pertumbuhan tanaman padi sawah. Klasifikasi kesetaraan iklim sebagai standar kalender tanam ditampilkan pada tabel 4.9

Tabel 4.9 Tabel kesetaraan iklim

Komoditas	Curah Hujan (mm/hari)	Suhu Udara (°C)	Kelembapan Udara (%)	Keputusan
Padi Sawah	5,7-16,7	24-29	33-90	Sesuai
	< 5,7 atau > 16,7	< 24 atau > 29	< 33 atau > 90	Tidak Sesuai

Setelah kriteria ditentukan, proses identifikasi dilakukan untuk menentukan tanggal-tanggal yang memenuhi syarat berdasarkan variabel penelitian. Hanya tanggal-tanggal (hari) yang memenuhi minimal dua dari tiga variabel (curah hujan, suhu udara, dan kelembapan udara) akan dipilih sebagai periode yang sesuai untuk penanaman dan dimasukkan ke dalam kalender tanam. Proses ini bertujuan untuk

meminimalkan risiko gagal panen akibat ketidaksesuaian kondisi cuaca dengan kebutuhan pertumbuhan padi sawah.

Apabila dua dari tiga variabel memenuhi syarat sesuai, maka tanggal tersebut dianggap sebagai waktu ideal untuk penanam padi sawah atau sebagai masa tanam. Namun, jika hanya satu variabel saja yang memenuhi syarat sesuai maka tanggal tersebut dikategorikan sebagai masa istirahat tanam atau masa bera. Masa bera ini penting untuk memberikan jeda waktu dalam siklus budidaya tanaman, yang memungkinkan tanah beristirahat serta meningkatkan kesuburan lahan sebelum memasuki musim tanam berikutnya. Kalender tanam padi sawah untuk rentang waktu November 2024 hingga Oktober 2025 dapat dilihat pada Lampiran 14 dan Tabel 4.10.

Tabel 4.10 Tabel kalender tanam Aceh Besar tahun 2025

Bulan	Nov	Des	Jan	Feb	Mar	Apr	Mei	Jun	Jul	Ags	Sep	Okt
Padi	Tanam							Bera			Tanam	

Berdasarkan hasil analisis dan kalender tanam yang disusun dalam penelitian ini, masa tanam yang sesuai di wilayah Aceh Besar adalah pada Oktober hingga April. Rentang waktu ini dipengaruhi oleh kesesuaian curah hujan, suhu udara, dan kelembapan udara relatif yang mendukung pertumbuhan yang baik untuk tanaman padi sawah. Sementara itu, bulan Mei hingga Agustus ditetapkan sebagai masa istirahat tanam. Pada masa bera, lahan dapat dimanfaatkan untuk pemeliharaan atau perbaikan kualitas tanah seperti pengolahan lahan, penambahan pupuk organik dan peningkatan kesuburan tanah sehingga mendukung keberlanjutan produksi di masa tanam berikutnya.

Penggunaan kalender tanam ini diharapkan dapat menjadi acuan awal dalam perencanaan kegiatan budidaya pertanian yang lebih efektif dan berkelanjutan. Dengan mengetahui waktu tanam yang paling tepat serta masa bera, petani memiliki panduan untuk meminimalkan risiko gagal panen akibat ketidaksesuaian beberapa kondisi iklim.

BAB V

KESIMPULAN DAN SARAN

5.1 KESIMPULAN

Berdasarkan hasil penelitian dan analisis yang telah dilakukan diperoleh kesimpulan sebagai berikut :

1. Hasil analisis LSTM menunjukkan akurasi yang lebih baik dengan tingkat kesalahan yang lebih kecil dibandingkan dengan *Holt-Winters*, yang diukur menggunakan metrik evaluasi RMSE (*Root Mean Square Error*) dan MAE (*Mean Absolute Error*). Oleh karena itu, LSTM dipilih sebagai model yang paling tepat untuk meramalkan curah hujan, suhu udara dan kelembapan udara (relatif) di Kabupaten Aceh Besar dengan data bersumber dari NASA maupun BMKG.

Berdasarkan hasil peramalan dengan tingkat kesalahan paling rendah yaitu model LSTM dengan pembagian data 90 : 10 pada data NASA diperoleh nilai RMSE = 0,057 dan MAE = 0,033 pada curah hujan, nilai RMSE = 0,107 dan MAE = 0,083 pada variabel kelembapan udara (relatif), dan suhu udara dengan nilai RMSE = 0,080 dan MAE = 0,064. Model tersebut digunakan untuk peramalan beberapa kondisi iklim dalam perencanaan kalender tanam.

2. Berdasarkan kalender tanam yang diperoleh periode yang paling sesuai untuk penanaman padi sawah di wilayah Aceh Besar adalah September hingga Mei. Sementara itu, periode Juni hingga Agustus dikategorikan sebagai masa istirahat tanam atau masa bera karena kondisi iklim cenderung kurang mendukung yang dapat menghambat proses pertumbuhan tanaman.

5.2 SARAN

Berdasarkan penelitian yang telah dilakukan, disarankan untuk melakukan integrasi data BMKG sehingga dapat meminimalkan kekosongan data di masa depan, sehingga penggunaan data lokal lebih efektif digunakan. Dan saran yang dapat diberikan untuk penelitian selanjutnya adalah mengembangkan metode LSTM untuk mendapatkan peramalan secara *real-time* sehingga sektor pertanian lebih responsif terhadap perubahan pola cuaca akibat perubahan iklim sehingga dapat mengoptimalkan produktivitas lahan.

DAFTAR PUSTAKA

- Agarwal, H. (2021). Predictive Data Analysis: Leveraging RNN and LSTM Techniques for Time Series Dataset. In *International Conference on Machine Learning and Data Engineering* (pp. 979–989). Published : Elsevier B.V.
- Banjarnahor, D., & Simanjuntak, B. H. (2015). Pola Tanam Kabupaten Sumba Tengah yang Sesuai dengan Curah Hujan Setempat. *Prosiding Konser Karya Ilmiah Nasional*, 1(2), 97-107.
- Bisht, D., & Ram, M. (2021). *Recent Advances in Time Series Forecasting*. CRC Press, Boca Raton.
- Carnegie, M., & Chairani. (2023). Perbandingan Long Short Term Memory (LSTM) dan Gated Recurrent Unit (GRU) Untuk Memprediksi Curah Hujan. *Jurnal Media Informatika Budidarma*, 7(3), 1022-1032.
- Djaenudin, D., Marwan, H., Subagjo, H., & A. Hidayat. (2011). *Petunjuk Teknis Evaluasi Lahan Untuk Komoditas Pertanian*. Balai Besar Litbang Sumberdaya Lahan Pertanian, Badan Litbang Pertanian, Bogor.
- DLHK (Dinas Lingkungan Hidup dan Kehutanan) Aceh. *Perubahan Iklim*. Diperoleh 3 Agustus 2024, dari <https://dlhk.acehprov.go.id>.
- Fadholi, Akhmad. (2023). Pemanfaatan Suhu Udara Dan Kelembapan Udara Dalam Persamaan Regresi Untuk Simulasi Prediksi Total Hujan Bulanan Di Pangkalpinang. *Jurnal CAUCHY*, 3(1), 1-9.
- Febriyanti, A. N. & Rifai, N. A. (2022). Metode Triple Exponential Smoothing Holt-Winters untuk Peramalan Jumlah Penumpang Kereta Api di Pulau Jawa. *Bandung Conference Series: Statistics*, 2(2), 152-158.
- Hazirah, A., Al-Hadi, I. Z., Amidon, A., Huzir, H., Ismail, N., Yusoff, Z., Tajuddin, S., & Taib, M. (2023). Boxplot Analysis Of 4 Grade Agarwood Essential Oil For Various Grades. *Indonesian Journal of Electrical Engineering and Computer Science*, 29(1), 238-244.
- Hendra, Y., Mukhtar, H., Baidrus & Hafsari, R. (2023). Prediksi Curah Hujan di Kota Pekanbaru Menggunakan LSTM (Long Short Term Memory). *Jurnal Software Engineering and Information System (SEIS)*, 3(2), 74-81.
- Hutapea, T., & Siahaan, A. (2023). Peramalan Curah Hujan Menggunakan Metode Holt-Winters Exponential Smoothing Di Kabupaten Padang Lawas Utara. *Journal of Student Research*, 1(2), 378-393.
- Hyndman, R., Koehler, A., & Ord, J. (2008). *Forecasting with Exponential Smoothing*. Springer-Verlag, Berlin.

- Lazzeri, Francesca. (2021). *Machine Learning for Time Series Forecasting with Python*. John Wiley & Sons, Canada.
- Lattifia, T., Wira Buana, P., & Rusjayanthi, N. K. D. (2022). Model Prediksi Cuaca Menggunakan Metode LSTM. *JITTER Jurnal Ilmiah Teknologi Dan Komputer*, 3(1), 994–1000.
- Montgomery, D. C., Jennings, C., & Kulahci, M. (2024). *Introduction to Time Series Analysis and Forecasting. Applied Sciences*. John Wiley & Sons, Canada.
- Novelia, R., Suminarti, N. E., & Setiawan, A. (2024). Dampak Variabilitas Unsur-Unsur Iklim Terhadap Produktivitas Tanaman Padi (*Oryza sativa* L.) di Wilayah Jawa Timur. *Journal Produksi Tanam*, 12(3), 176-183.
- Pertiwi, D. D. (2020). Applied Exponential Smoothing Holt-Winter Method for Rainfall Forecast in Mataram City. *Journal of Intelligent Computing and Health Informatics*, 1(2), 21–24.
- Praasetyo, M. A., Mahdiah, U., & Swanjaya, D. (2023). Penerapan Metode Holt Winters Untuk Peramalan Harga Saham PT Prodia Widyahusada Tbk. *SKANIKA: Sistem Komputer dan Teknik Informatika*, 6(1), 75–84.
- Pryanto, G. H., Hartomo, K., & Pekereng, M. (2013). Perancangan Kalender Tanam Berdasarkan Data Klimatologi Menggunakan Metode Forecasting Holt-Winters (Studi Kasus : Boyolali). *Teknologi Informasi*, 7(1), 96–109.
- Rismawati, Y. & Darsyah, M. (2018). Perbandingan Peramalan Metode Moving Average dan Exponential Smoothing Holt Winter Untuk Menentukan Peramalan Inflasi di Indonesia. *Prosiding Seminar Nasional Mahasiswa Unimus* (330-335). Semarang : Unimus.
- Rosita, Y., & Moonlight, L. (2024). Perbandingan Metode Prediksi untuk Nilai Jual USD: Holt-Winters, Holt's, dan Single Exponential Smoothing. *Jurnal Teknologi Informasi dan Multimedia*, 5(4), 322-333.
- Sagheer, A., & Kotb, M. (2019). Time Series Forecasting of Petroleum Production Using Deep LSTM Recurrent Networks. *Neurocomputing*, 323, 203–213.
- Sari, K., Indrawati, E., & Nevita, A. (2020). Analisis Perbedaan Suhu dan Kelembapan Ruangan Pada Kamar Berdinding Keramik. *Jurnal Infokar*, 1(2), 5-11.
- Selle, N., Yudistira, N., & Dewi, C. (2022). Perbandingan Prediksi Penggunaan Listrik dengan Menggunakan Metode Long Short Term Memory (Lstm) dan Recurrent Neural Network (RNN). *Jurnal Teknologi Informasi dan Ilmu Komputer*, 9(1), 155-162.
- Seprima, M., & Defrianto (2020). Prediksi Curah Hujan Dan Kelembapan Udara Kota

- Pekanbaru Menggunakan Metode Monte Carlo. *Jurnal UNRI*, 17(3), 134-138.
- Setiawan, L., Susanti, D. & Riaman. (2023). Analisis Perbandingan Hasil Peramalan Harga Saham Menggunakan Model Autoregressive Integrated Moving Average dan Long Short Term Memory. *Jurnal Matematika Integratif*, 19(2), 223-234.
- Sujalu, A. P., Pulihasih, A. Y. & Biantary, M. P. (2022). Instrumentasi Klimatologi dan Meteorologi. Zahir Publishing, Yogyakarta.
- Suryantara, G. N. (2024). *PYTHON: Implementasi Algoritma Kompleks dalam Era Industri 5.0 dan Society 5.0*. PT. Elex Media Komputindo, Jakarta.
- Suryanto, A. A. & Muqtadir, A. (2019). Penerapan Metode Mean Absolute Error (MAE) untuk Prediksi Produksi Padi. *Jurnal Teknik Informatika*, 11(1), 78-83.
- Thomas, E. B. (2023, July 29). Understanding LSTM : An In-depth Look at its Architecture, Functioning, and Pros & Cons. https://medium.com/@ebinbabuthomas_21082/understanding-lstm-an-in-depth-look-at-its-architecture-functioning-and-pros-cons-5424dd7215e6.
- Winarno, G. D., Harianto, S. P. & Santoso, Trio. (2019). Klimatologi Pertanian. Pustaka Media, Bandar Lampung.
- White, J. W., Hoogenboom, G., Jr. P. W. S., & Hoell, J. M. (2008). Evaluation of NASA satellite-and assimilation model-derived long-term daily temperature data over the continental US. *Agricultural and Forest Meteorology*, 148(10), 1574-1584.

LAMPIRAN

Lampiran 1. Data Penelitian

BMKG				
No	Tanggal	Curah Hujan	Kelembapan Udara (Relatif)	Suhu Udara
1	1/1/2011	22	89	25.2
2	1/2/2011	5	85	26.5
3	1/3/2011	5	86	26.8
4	1/4/2011	16	89	25.9
5	1/5/2011	0	85	26.5
6	1/6/2011	17	85	26.2
7	1/7/2011	0	90	25
8	1/8/2011	2	90	24.9
9	1/9/2011	0	80	25.5
10	1/10/2011	14	90	25.5
11	1/11/2011	0	82	26.1
12	1/12/2011	0	80	26.2
13	1/13/2011	0	81	26.2
14	1/14/2011	0	82	26.7
15	1/15/2011	0	83	26
16	1/16/2011	0	83	26.1
17	1/17/2011	0	80	26.9
18	1/18/2011	0	82	26
19	1/19/2011	0	80	25.4
20	1/20/2011	0	76	25.8
21	1/21/2011	0	76	26.2
22	1/22/2011	0	78	26
23	1/23/2011	0	73	27
24	1/24/2011	0	82	26.5
25	1/25/2011	4	82	26
26	1/26/2011	0	78	27
27	1/27/2011	47	90	25.4
28	1/28/2011	7	91	24.8
29	1/29/2011	14	94	24.8
30	1/30/2011	0	82	26.8
⋮	⋮	⋮	⋮	⋮
5052	10/30/2024	0	76	27.3
5053	10/31/2024	0	74	27.7

NASA				
No	Tanggal	Curah Hujan	Kelembapan Udara (Relatif)	Suhu Udara
1	1/1/2011	10.95	81.94	26.02
2	1/2/2011	6.97	84.81	25.93
3	1/3/2011	4.85	80.88	26.1
4	1/4/2011	9.94	80.56	25.73
5	1/5/2011	5.04	84	25.6
6	1/6/2011	9.82	82.94	25.19
7	1/7/2011	4.24	76.31	25.42
8	1/8/2011	7.68	86.88	25.01
9	1/9/2011	4.37	78.62	25.55
10	1/10/2011	11.62	82.94	25.08
11	1/11/2011	0.14	78.75	25.26
12	1/12/2011	0	80.94	25.55
13	1/13/2011	0	78.62	26.16
14	1/14/2011	0	76.38	26.44
15	1/15/2011	0	80.25	26.16
16	1/16/2011	4.81	83.5	25.74
17	1/17/2011	0.66	79.69	26.18
18	1/18/2011	0.13	78.12	25.49
19	1/19/2011	0.09	80.81	25.29
20	1/20/2011	1.15	77.12	26.02
21	1/21/2011	0.03	73.31	26.01
22	1/22/2011	0.01	73.75	26.12
23	1/23/2011	4.34	79.06	26.33
24	1/24/2011	2.14	76.19	26.53
25	1/25/2011	6.87	84.62	25.83
26	1/26/2011	12.65	83.06	26
27	1/27/2011	27.62	89.38	25.6
28	1/28/2011	24.66	90.06	25.56
29	1/29/2011	18.02	87.62	25.46
30	1/30/2011	3.89	86.81	25.23
⋮	⋮	⋮	⋮	⋮
5052	10/30/2024	1.97	79.31	27.35
5053	10/31/2024	0.41	75.31	27.82

Lampiran 2. Ringkasan Statistik dan Proses Imputasi

```
df.describe()
#BMKG Sebelum Imputasi
```

	Suhu	Kelembaban	Curah_Hujan
count	4808.000000	4808.000000	3478.000000
mean	27.362230	78.897671	8.775446
std	1.231762	7.405878	19.213520
min	23.100000	46.000000	0.000000
25%	26.500000	75.000000	0.000000
50%	27.300000	80.000000	0.800000
75%	28.200000	84.000000	8.000000
max	33.000000	98.000000	200.000000

```
df.describe()
#NASA Sebelum Imputasi
```

	Suhu	Kelembaban	Curah_Hujan
count	5050.000000	5050.000000	5050.000000
mean	26.990713	79.178727	6.194432
std	0.826380	4.462853	10.158024
min	24.370000	63.690000	0.000000
25%	26.410000	76.250000	0.740000
50%	26.950000	79.250000	2.665000
75%	27.550000	82.250000	7.060000
max	30.070000	92.000000	149.120000

```
# Mengisi data kosong dengan mean dari masing-masing kolom
cols_to_fill = ['Curah_Hujan', 'Kelembaban', 'Suhu'] # Kolom target

for col in cols_to_fill:
    mean_value = df[col].mean() # Menghitung mean dari kolom
    df[col] = df[col].fillna(mean_value) # Mengisi nilai kosong dengan mean

print(df)
```

```
df.describe()
#BMKG Setelah Imputasi
```

	Suhu	Kelembaban	Curah_Hujan
count	5053.000000	5053.000000	5053.000000
mean	27.362230	78.897671	8.775446
std	1.201523	7.224070	15.939607
min	23.100000	46.000000	0.000000
25%	26.600000	75.000000	0.000000
50%	27.362230	79.000000	6.500000
75%	28.100000	84.000000	8.775446
max	33.000000	98.000000	200.000000

```
df.describe()
#Nasa Setelah Imputasi
```

	Suhu	Kelembaban	Curah_Hujan
count	5053.000000	5053.000000	5053.000000
mean	26.990713	79.178727	6.194432
std	0.826134	4.461528	10.155008
min	24.370000	63.690000	0.000000
25%	26.410000	76.250000	0.740000
50%	26.950000	79.250000	2.670000
75%	27.550000	82.250000	7.060000
max	30.070000	92.000000	149.120000

Lampiran 3. Pemrosesan Plot Deret Waktu

```
plt.figure(figsize=(15, 6), dpi=100)
plt.title('Curah Hujan Data NASA')
plt.plot(df['Curah_Hujan'])
```

```
plt.figure(figsize=(15, 6), dpi=100)
plt.title('Kelembaban Udara (relatif) Data NASA')
plt.plot(df['Kelembaban'])
```

```
plt.figure(figsize=(15, 6), dpi=100)
plt.title('Suhu Udara Data NASA')
plt.plot(df['Suhu'])
```

Lampiran 4. Pemrosesan Plot Dekomposisi

```
ch_decompose = seasonal_decompose(df['Curah_Hujan'], model = "additive",
                                   period=365)

fig = ch_decompose.plot()
fig.set_size_inches(16,9)
plt.title('Curah Hujan Data NASA')
plt.show()

kl_decompose = seasonal_decompose(df['Kelembaban'], model = "additive",
                                   period=365)

fig = kl_decompose.plot()
fig.set_size_inches(16,9)
plt.title('Kelembaban Udara (relatif) Data NASA')
plt.show()

sh_decompose = seasonal_decompose(df['Suhu'], model = "additive", period=365)
fig = sh_decompose.plot()
fig.set_size_inches(16,9)
plt.title('Suhu Udara Data NASA')
plt.show()
```

Lampiran 5. Pemrosesan untuk Output Boxplot

```
fig, ax = plt.subplots(figsize=(24,10))
sns.boxplot(x = df.index.year,
            y = df['Curah_Hujan'],
            ax = ax)
plt.title('Curah Hujan Data NASA')

fig, ax = plt.subplots(figsize=(24,10))
sns.boxplot(x = df.index.year,
            y = df['Kelembaban'],
            ax = ax)
plt.title('Kelembaban Udara (relatif) Data NASA')

fig, ax = plt.subplots(figsize=(24,10))
sns.boxplot(x = df.index.year,
            y = df['Suhu'],
            ax = ax)
plt.title('Suhu Udara Data NASA')
```

Lampiran 6. Model Holt-Winters dan Perbandingan Hasil Peramalan Curah Hujan BMKG

- Pembagian Data 70:30

```
ExponentialSmoothing Model Results
=====
Dep. Variable:    Curah_Hujan    No. Observations:    3537
Model:            ExponentialSmoothing    SSE                679839.771
Optimized:        True            AIC                19339.591
Trend:            Additive        BIC                21622.874
Seasonal:         Additive        AICC               19427.300
Seasonal Periods: 365            Date:              Tue, 10 Dec 2024
Box-Cox:          False          Time:              09:54:28
Box-Cox Coeff.:   None
=====
```

	coeff	code	optimized
smoothing_level	0.0328912	alpha	True
smoothing_trend	6.9603e-05	beta	True
smoothing_seasonal	0.0554756	gamma	True

```
#Splitting data 70:30
from sklearn.metrics import mean_absolute_percentage_error, mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 11.38
MSE: 365.81
RMSE: 19.13

- **Pembagian Data 80:20**

ExponentialSmoothing Model Results			
Dep. Variable:	Curah_Hujan	No. Observations:	4042
Model:	ExponentialSmoothing	SSE	918065.860
Optimized:	True	AIC	22669.990
Trend:	Additive	BIC	25002.653
Seasonal:	Additive	AICC	22745.627
Seasonal Periods:	365	Date:	Tue, 10 Dec 2024
Box-Cox:	False	Time:	09:58:59
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.0997865	alpha	True
smoothing_trend	0.0036051	beta	True
smoothing_seasonal	0.0694617	gamma	True

```
#Splitting data 80:20
from sklearn.metrics import mean_absolute_percentage_error, mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 11.35
MSE: 329.03
RMSE: 18.14

- **Pembagian Data 90:10**

ExponentialSmoothing Model Results			
Dep. Variable:	Curah_Hujan	No. Observations:	4547
Model:	ExponentialSmoothing	SSE	1131951.406
Optimized:	True	AIC	25826.848
Trend:	Additive	BIC	28203.070
Seasonal:	Additive	AICC	25893.334
Seasonal Periods:	365	Date:	Tue, 10 Dec 2024
Box-Cox:	False	Time:	10:01:06
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.0557349	alpha	True
smoothing_trend	0.0004323	beta	True
smoothing_seasonal	0.0830000	gamma	True

```
#Splitting data 90:10
from sklearn.metrics import mean_absolute_percentage_error, mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 7.38
MSE: 194.59
RMSE: 13.95

Lampiran 7. Model Holt-Winters dan Perbandingan Hasil Peramalan Kelembapan Udara BMKG

- Pembagian Data 70:30

ExponentialSmoothing Model Results			
Dep. Variable:	Kelembaban	No. Observations:	3537
Model:	ExponentialSmoothing	SSE	83942.508
Optimized:	True	AIC	11941.160
Trend:	Additive	BIC	14224.442
Seasonal:	Additive	AICC	12028.869
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	02:06:58
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.3313052	alpha	True
smoothing_trend	9.8898e-05	beta	True
smoothing_seasonal	0.0015996	gamma	True

```
#Splitting data 70:30
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 8.59

RMSE: 10.11

- Pembagian Data 80:20

ExponentialSmoothing Model Results			
Dep. Variable:	Kelembaban	No. Observations:	4042
Model:	ExponentialSmoothing	SSE	98299.923
Optimized:	True	AIC	13639.168
Trend:	Additive	BIC	15971.832
Seasonal:	Additive	AICC	13714.805
Seasonal Periods:	365	Date:	Thu, 05 Dec 2024
Box-Cox:	False	Time:	12:55:26
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.3403461	alpha	True
smoothing_trend	0.0011324	beta	True
smoothing_seasonal	0.0085756	gamma	True

```
#Splitting data 80:20
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 5.07

RMSE: 6.47

- Pembagian Data 90:10

ExponentialSmoothing Model Results			
Dep. Variable:	Kelembaban	No. Observations:	4547
Model:	ExponentialSmoothing	SSE	110900.540
Optimized:	True	AIC	15263.873
Trend:	Additive	BIC	17640.096
Seasonal:	Additive	AICC	15330.359
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	02:10:28
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.3651108	alpha	True
smoothing_trend	0.0010958	beta	True
smoothing_seasonal	0.0174941	gamma	True

```
#Splitting data 90:10
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 9.45
RMSE: 11.01

Lampiran 8. Model Holt-Winters dan Perbandingan Hasil Peramalan Suhu Udara BMKG

- Pembagian Data 70:30

ExponentialSmoothing Model Results			
Dep. Variable:	Suhu	No. Observations:	3537
Model:	ExponentialSmoothing	SSE	2641.303
Optimized:	True	AIC	-292.828
Trend:	Additive	BIC	1990.455
Seasonal:	Additive	AICC	-205.119
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	02:15:27
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.2818503	alpha	True
smoothing_trend	4.9044e-09	beta	True
smoothing_seasonal	3.3558e-07	gamma	True

```
#Splitting data 70:30
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 1.22
RMSE: 1.46

- Pembagian Data 80:20

ExponentialSmoothing Model Results			
Dep. Variable:	Suhu	No. Observations:	4042
Model:	ExponentialSmoothing	SSE	3107.836
Optimized:	True	AIC	-322.290
Trend:	Additive	BIC	2010.373
Seasonal:	Additive	AICC	-246.653
Seasonal Periods:	365	Date:	Thu, 05 Dec 2024
Box-Cox:	False	Time:	13:01:27
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.2898059	alpha	True
smoothing_trend	7.7098e-08	beta	True
smoothing_seasonal	7.7701e-08	gamma	True

```
#Splitting data 80:20
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 0.86

RMSE: 1.09

- Pembagian Data 90: 10

ExponentialSmoothing Model Results			
Dep. Variable:	Suhu	No. Observations:	4547
Model:	ExponentialSmoothing	SSE	3437.308
Optimized:	True	AIC	-532.155
Trend:	Additive	BIC	1844.067
Seasonal:	Additive	AICC	-465.670
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	02:19:22
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.2948718	alpha	True
smoothing_trend	4.2618e-09	beta	True
smoothing_seasonal	1.0087e-07	gamma	True

```
#Splitting data 90:10
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 0.92

RMSE: 1.20

Lampiran 9. Model Holt-Winters dan Perbandingan Hasil Peramalan Curah Hujan NASA

- Pembagian Data 70:30

```

=====
ExponentialSmoothing Model Results
=====
Dep. Variable:          Curah_Hujan    No. Observations:          3537
Model:                  ExponentialSmoothing    SSE                248240.027
Optimized:              True            AIC                15776.202
Trend:                  Additive         BIC                18059.484
Seasonal:               Additive         AICC              15863.911
Seasonal Periods:      365             Date:              Tue, 10 Dec 2024
Box-Cox:                False           Time:              10:14:45
Box-Cox Coeff.:        None
=====

```

	coeff	code	optimized
smoothing_level	0.4370830	alpha	True
smoothing_trend	0.0214616	beta	True
smoothing_seasonal	0.0299499	gamma	True

```

#Splitting 70 : 30
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')

MAE: 7.85
MSE: 138.06
RMSE: 11.75

```

- Pembagian Data 80:20

```

=====
ExponentialSmoothing Model Results
=====
Dep. Variable:          Curah_Hujan    No. Observations:          4042
Model:                  ExponentialSmoothing    SSE                334418.068
Optimized:              True            AIC                18588.067
Trend:                  Additive         BIC                20920.730
Seasonal:               Additive         AICC              18663.704
Seasonal Periods:      365             Date:              Tue, 10 Dec 2024
Box-Cox:                False           Time:              10:18:04
Box-Cox Coeff.:        None
=====

```

	coeff	code	optimized
smoothing_level	0.3887302	alpha	True
smoothing_trend	0.0125533	beta	True
smoothing_seasonal	0.0775682	gamma	True

```

#Splitting 80 : 20
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')

MAE: 6.55
MSE: 127.88
RMSE: 11.31

```

- Pembagian Data 90:10

```

=====
ExponentialSmoothing Model Results
=====
Dep. Variable:          Curah_Hujan      No. Observations:      4547
Model:                  ExponentialSmoothing  SSE                    409212.698
Optimized:              True              AIC                    21200.442
Trend:                  Additive           BIC                    23576.665
Seasonal:               Additive           AICC                   21266.928
Seasonal Periods:      365               Date:                  Tue, 10 Dec 2024
Box-Cox:                False             Time:                  10:19:31
Box-Cox Coeff.:        None
=====

```

	coeff	code	optimized
smoothing_level	0.3552285	alpha	True
smoothing_trend	0.0062059	beta	True
smoothing_seasonal	0.0844516	gamma	True

```

#Splitting 90 : 10
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Curah_Hujan'] - test_pred)
mae = np.mean(np.abs(errors))
mse = mean_squared_error(test['Curah_Hujan'], test_pred)
rmse = np.sqrt(mse)

# Print results
print(f'MAE: {mae:.2f}')
print(f'MSE: {mse:.2f}')
print(f'RMSE: {rmse:.2f}')

MAE: 5.63
MSE: 112.01
RMSE: 10.58

```

Lampiran 10. Model Holt-Winters dan Perbandingan Hasil Peramalan Kelembapan Udara NASA

- Pembagian Data 70:30

```

=====
ExponentialSmoothing Model Results
=====
Dep. Variable:          Kelembaban      No. Observations:      3537
Model:                  ExponentialSmoothing  SSE                    35157.232
Optimized:              True              AIC                    8862.902
Trend:                  Additive           BIC                    11146.185
Seasonal:               Additive           AICC                   8950.612
Seasonal Periods:      365               Date:                  Wed, 04 Dec 2024
Box-Cox:                False             Time:                  22:24:38
Box-Cox Coeff.:        None
=====

```

	coeff	code	optimized
smoothing_level	0.5005712	alpha	True
smoothing_trend	6.95e-05	beta	True
smoothing_seasonal	0.0002830	gamma	True

```

#Splitting data 70:30
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')

MAE: 3.85
RMSE: 4.88

```

- Pembagian Data 80:20

ExponentialSmoothing Model Results			
Dep. Variable:	Kelembaban	No. Observations:	4042
Model:	ExponentialSmoothing	SSE	41194.339
Optimized:	True	AIC	10123.751
Trend:	Additive	BIC	12456.414
Seasonal:	Additive	AICC	10199.387
Seasonal Periods:	365	Date:	Thu, 05 Dec 2024
Box-Cox:	False	Time:	13:18:56
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.4980140	alpha	True
smoothing_trend	2.7341e-05	beta	True
smoothing_seasonal	6.9601e-05	gamma	True

```
#Splitting data 80:20
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 4.48

RMSE: 5.38

- Pembagian Data 90:10

ExponentialSmoothing Model Results			
Dep. Variable:	Kelembaban	No. Observations:	4547
Model:	ExponentialSmoothing	SSE	47263.328
Optimized:	True	AIC	11385.741
Trend:	Additive	BIC	13761.964
Seasonal:	Additive	AICC	11452.227
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	22:08:06
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.4925133	alpha	True
smoothing_trend	8.8961e-05	beta	True
smoothing_seasonal	0.0001608	gamma	True

```
#Splitting data 90:10
from sklearn.metrics import mean_squared_error
# Calculate errors
errors = abs(test['Kelembaban'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 4.66

RMSE: 5.59

Lampiran 11. Model Holt-Winters dan Perbandingan Hasil Peramalan Suhu Udara NASA

- Pembagian Data 70:30

ExponentialSmoothing Model Results			
=====			
Dep. Variable:	Suhu	No. Observations:	3537
Model:	ExponentialSmoothing	SSE	691.566
Optimized:	True	AIC	-5032.649
Trend:	Additive	BIC	-2749.366
Seasonal:	Additive	AICC	-4944.940
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	22:58:25
Box-Cox Coeff.:	None		
=====			
	coeff	code	optimized

smoothing_level	0.6186757	alpha	True
smoothing_trend	1.5729e-09	beta	True
smoothing_seasonal	1.2182e-07	gamma	True

```
#Splitting data 70:30
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 0.66

RMSE: 0.83

- Pembagian Data 80:20

ExponentialSmoothing Model Results			
=====			
Dep. Variable:	Suhu	No. Observations:	4042
Model:	ExponentialSmoothing	SSE	799.488
Optimized:	True	AIC	-5810.157
Trend:	Additive	BIC	-3477.494
Seasonal:	Additive	AICC	-5734.520
Seasonal Periods:	365	Date:	Thu, 05 Dec 2024
Box-Cox:	False	Time:	13:22:45
Box-Cox Coeff.:	None		
=====			
	coeff	code	optimized

smoothing_level	0.6226564	alpha	True
smoothing_trend	2.5924e-09	beta	True
smoothing_seasonal	3.7181e-07	gamma	True

```
#Splitting data 80:20
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 0.61

RMSE: 0.77

- **Pembagian Data 90:10**

ExponentialSmoothing Model Results			
Dep. Variable:	Suhu	No. Observations:	4547
Model:	ExponentialSmoothing	SSE	904.157
Optimized:	True	AIC	-6604.403
Trend:	Additive	BIC	-4228.181
Seasonal:	Additive	AICC	-6537.918
Seasonal Periods:	365	Date:	Wed, 04 Dec 2024
Box-Cox:	False	Time:	22:54:22
Box-Cox Coeff.:	None		
	coeff	code	optimized
smoothing_level	0.6043650	alpha	True
smoothing_trend	1.323e-09	beta	True
smoothing_seasonal	6.0241e-07	gamma	True

```
#Splitting data 90:10
# Calculate errors
errors = abs(test['Suhu'] - test_pred)
mae = np.mean(np.abs(errors))
mse = np.mean(errors**2)
rmse = np.sqrt(mse)

print(f'MAE: {mae:.2f}')
print(f'RMSE: {rmse:.2f}')
```

MAE: 0.68

RMSE: 0.84

Lampiran 12. Model LSTM

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout
from tensorflow.keras.callbacks import EarlyStopping, ModelCheckpoint

# Create the LSTM model
model = Sequential()

# Add LSTM Layers with dropout
model.add(LSTM(units=128, input_shape=(train_x.shape[1], train_x.shape[2]), return_sequences=True))
model.add(Dropout(0.2))

model.add(LSTM(units=64, return_sequences=True))
model.add(Dropout(0.2))

model.add(LSTM(units=32, return_sequences=False))
model.add(Dropout(0.2))

# Add a dense output layer
model.add(Dense(units=1))

# Compile the model
model.compile(optimizer='adam', loss='mean_squared_error')
```

Lampiran 13. Peramalan Curah Hujan BMKG dengan Metode LSTM

- **Pembagian Data 70:30**

```
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)

48/48 [=====] - 0s 6ms/step
Mean Absolute Error (MAE): 0.050618214799585115
Mean Squared Error (MSE): 0.0083730547840057
Root Mean Squared Error (RMSE): 0.09150439762112912
```

- **Pembagian Data 80:20**

```
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

32/32 [=====] - 2s 6ms/step
Mean Absolute Error (MAE): 0.04620051638094659
Mean Squared Error (MSE): 0.0066409722624404905
Root Mean Squared Error (RMSE): 0.08149216074224865

- **Pembagian Data 90:10**

```
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

16/16 [=====] - 1s 6ms/step
Mean Absolute Error (MAE): 0.0399851793657654
Mean Squared Error (MSE): 0.004075159336008677
Root Mean Squared Error (RMSE): 0.06383697467775769

Lampiran 14. Peramalan Kelembapan Udara BMKG dengan Metode LSTM

- **Pembagian Data 70:30**

```
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

48/48 [=====] - 0s 10ms/step
Mean Absolute Error (MAE): 0.07598163975782743
Mean Squared Error (MSE): 0.009721832263572079
Root Mean Squared Error (RMSE): 0.0985993522472236

- Pembagian Data 80:20

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

32/32 [=====] - 2s 10ms/step
Mean Absolute Error (MAE): 0.07582929212617887
Mean Squared Error (MSE): 0.009776081757933661
Root Mean Squared Error (RMSE): 0.09887407020009675

- Pembagian Data 90:10

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
# Also, 'test_x' and 'test_y' should be available

# Predict temperatures using the trained model
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

16/16 [=====] - 2s 9ms/step
Mean Absolute Error (MAE): 0.07761035777191488
Mean Squared Error (MSE): 0.01057455347048248
Root Mean Squared Error (RMSE): 0.10283264788228727

Lampiran 15. Peramalan Suhu Udara BMKG dengan Metode LSTM

- Pembagian Data 70:30

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
# Also, 'test_x' and 'test_y' should be available
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

48/48 [=====] - 4s 10ms/step
Mean Absolute Error (MAE): 0.06898071230513562
Mean Squared Error (MSE): 0.00804193279090546
Root Mean Squared Error (RMSE): 0.0896768241571113

- Pembagian Data 80:20

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
# Also, 'test_x' and 'test_y' should be available
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)

32/32 [=====] - 2s 7ms/step
Mean Absolute Error (MAE): 0.06639085017865412
Mean Squared Error (MSE): 0.007362769634721604
Root Mean Squared Error (RMSE): 0.08580658270040595
```

- Pembagian Data 90:10

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
# Also, 'test_x' and 'test_y' should be available
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)

16/16 [=====] - 1s 5ms/step
Mean Absolute Error (MAE): 0.06969351638900191
Mean Squared Error (MSE): 0.00815567647100119
Root Mean Squared Error (RMSE): 0.0903087840190598
```

Lampiran 16. Peramalan Curah Hujan NASA dengan Metode LSTM

- Pembagian Data 70:30

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)

48/48 [=====] - 1s 5ms/step
Mean Absolute Error (MAE): 0.041925202515947384
Mean Squared Error (MSE): 0.005069468493819856
Root Mean Squared Error (RMSE): 0.07120020009676838
```

- Pembagian Data 80:20

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
32/32 [=====] - 2s 5ms/step
Mean Absolute Error (MAE): 0.03656453230312931
Mean Squared Error (MSE): 0.004495790866429248
Root Mean Squared Error (RMSE): 0.06705065895596589
```

- Pembagian Data 90:10

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
16/16 [=====] - 1s 6ms/step
Mean Absolute Error (MAE): 0.03271018449232019
Mean Squared Error (MSE): 0.0031963217087424903
Root Mean Squared Error (RMSE): 0.05653602133810347
```

Lampiran 17. Peramalan Kelembapan Udara Nasa dengan Metode LSTM

- Pembagian Data 70:30

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
48/48 [=====] - 1s 5ms/step
Mean Absolute Error (MAE): 0.08715662266339401
Mean Squared Error (MSE): 0.012649013032102037
Root Mean Squared Error (RMSE): 0.11246783109895041
```

- Pembagian Data 80:20

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
32/32 [=====] - 2s 7ms/step
Mean Absolute Error (MAE): 0.08740030366924009
Mean Squared Error (MSE): 0.012793474874769962
Root Mean Squared Error (RMSE): 0.11310824406191602
```

- Pembagian Data 90:10

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
16/16 [=====] - 1s 5ms/step
Mean Absolute Error (MAE): 0.08344052727677174
Mean Squared Error (MSE): 0.011397054119884382
Root Mean Squared Error (RMSE): 0.1067569862813876
```

Lampiran 18. Peramalan Suhu Udara Nasa dengan Metode LSTM

- Pembagian Data 70:30

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 70:30
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
48/48 [=====] - 2s 6ms/step
Mean Absolute Error (MAE): 0.06289655360715823
Mean Squared Error (MSE): 0.006325472130163888
Root Mean Squared Error (RMSE): 0.07953283680445385
```

- Pembagian Data 80:20

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 80:20
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
32/32 [=====] - 1s 5ms/step
Mean Absolute Error (MAE): 0.06316928545698011
Mean Squared Error (MSE): 0.006400384311361991
Root Mean Squared Error (RMSE): 0.08000240190995513
```

- Pembagian Data 90:10

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
predictions = model.predict(test_x)

# Calculate evaluation metrics 90:10
mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

print("Mean Absolute Error (MAE):", mae)
print("Mean Squared Error (MSE):", mse)
print("Root Mean Squared Error (RMSE):", rmse)
```

```
16/16 [=====] - 1s 6ms/step
Mean Absolute Error (MAE): 0.06353752046949421
Mean Squared Error (MSE): 0.006381744292333358
Root Mean Squared Error (RMSE): 0.07988582034587463
```

Lampiran 19. Hasil Peramalan Dengan Metode Terbaik dengan Keputusan Kesetaraan Iklim

Tanggal	Curah Hujan	Suhu Udara	Kelembapan Udara Relatif	Kategori Curah Hujan	Keputusan Curah Hujan	Keputusan Suhu Udara	Keputusan Kelembapan Udara	Keputusan
11/1/2024	2.91	27.62	77.11	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/2/2024	2.8	28	75.88	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/3/2024	3.58	27.96	76.11	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/4/2024	4.43	27.88	75.34	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/5/2024	3.75	27.97	74.76	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/6/2024	2.6	28	74.8	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/7/2024	2.57	27.91	75.84	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/8/2024	3.82	27.72	76.72	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/9/2024	2.86	28.16	75.08	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/10/2024	3.71	27.59	76.6	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam

11/11/2024	6.47	27.29	78.56	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
11/12/2024	3.63	27.31	78.97	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/13/2024	10.89	26.99	78.15	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
11/14/2024	10.36	26.79	80.96	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
11/15/2024	7.37	27.11	77.88	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
11/16/2024	3.79	27.73	75.4	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/17/2024	2.93	27.71	77.37	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/18/2024	2.72	27.78	77	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/19/2024	3.89	27.39	77.02	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/20/2024	3.8	27.33	77.18	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/21/2024	3	28.13	73.33	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
11/22/2024	2.92	28.08	73.76	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
:	:	:	:	:	:	:	:	:
10/24/2025	4.45	27.85	75.49	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
10/25/2025	4.85	27.57	79.54	Hujan Ringan	Tidak Sesuai	Sesuai	Sesuai	Tanam
10/26/2025	6.41	27.48	79.88	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
10/27/2025	20.66	27.84	78.99	Hujan Sedang	Tidak Sesuai	Sesuai	Sesuai	Tanam
10/28/2025	12.09	27.45	78.98	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
10/29/2025	15.46	26.86	82.24	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
10/30/2025	7.3	27	80.37	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam
10/31/2025	10.63	27.71	75.91	Hujan Ringan	Sesuai	Sesuai	Sesuai	Tanam

Lampiran 20. Hasil Kalender Tanam

bulan_keputusan

	Bulan	Keputusan
0	January	Tanam
1	February	Tanam
2	March	Tanam
3	April	Tanam
4	May	Tanam
5	June	Bera
6	July	Bera
7	August	Bera
8	September	Tanam
9	October	Tanam
10	November	Tanam
11	December	Tanam

Lampiran 21. Biodata

BIODATA

1. Nama : Ema Dwi Chairani
2. Tempat,Tanggal Lahir : Batam, 02 Februari 2001
3. Alamat : Kec. Bandar, Simalungun, Sumatera Utara
4. Nama Ayah : MHD Ali Nafiah
5. Pekerjaan Ayah : Wirausaha
6. Nama Ibu : Flora Panjaitan
7. Pekerjaan Ibu : Ibu Rumah Tangga
8. Alamat Orang Tua : Kec. Bandar, Simalungun, Sumatera Utara
9. Riwayat Pendidikan :

Jenjang	Nama Sekolah	Bidang Studi	Tempat	Tahun Ijazah
SD	SD 010187	-	Sumatera Utara	2013
SLTP	SMPN 1 Bandar	-	Sumatera Utara	2016
SLTA	SMAN 1 Raya	IPA	Sumatera Utara	2019

Banda Aceh, 10 Maret 2024

Ema Dwi Chairani
NMP. 2108108010065